

UNIVERSIDADE FEDERAL DO ABC
PROGRAMA DE GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

CAIO CARDOSO DOS SANTOS
VICTOR RAVAZIO DE LIMA

**DETECÇÃO AUTOMÁTICA DE CONFLITOS TEXTUAIS
EM REDES SOCIAIS: UMA ABORDAGEM BASEADA NO
MODELO BERTIMBAU**

SANTO ANDRÉ, SP

2026

CAIO CARDOSO DOS SANTOS
VICTOR RAVAZIO DE LIMA

**DETECÇÃO AUTOMÁTICA DE CONFLITOS TEXTUAIS
EM REDES SOCIAIS: UMA ABORDAGEM BASEADA NO
MODELO BERTIMBAU**

Projeto de graduação apresentado à
Universidade Federal do ABC, Centro de
Matemática, Computação e Cognição, como
requisito parcial para obtenção do título de
Bacharel em Ciência da Computação.

Orientador: Dr. Carlos da Silva dos Santos

SANTO ANDRÉ, SP
2026

Dedicamos este trabalho às nossas famílias, pelo apoio durante toda a trajetória acadêmica.

AGRADECIMENTOS

Agradecemos, primeiramente, a Deus, pela força, sabedoria e perseverança concedidas ao longo desta trajetória, permitindo-nos superar os desafios e concluir esta etapa.

Agradecemos às nossas famílias pelo apoio, incentivo e compreensão durante toda a nossa trajetória acadêmica. Sem eles, este trabalho não seria possível.

Agradecemos à instituição de ensino pela oportunidade de formação e pelo ambiente proporcionado para o desenvolvimento acadêmico e científico. Estendemos nosso agradecimento a todo o corpo docente, pela dedicação, pelos conhecimentos transmitidos e pelo compromisso com a formação dos estudantes.

Por fim, agradecemos ao nosso orientador pela orientação, disponibilidade e pelas contribuições essenciais para o desenvolvimento deste trabalho. Seus conhecimentos e direcionamentos foram fundamentais para a conclusão desta pesquisa.

A todos que, direta ou indiretamente, contribuíram para esta conquista, expressamos nossa sincera gratidão.

“Programs must be written for people to read, and only incidentally for machines to execute.”

(Harold Abelson)

RESUMO

As redes sociais consolidaram-se como importantes espaços de debate público, favorecendo a circulação de opiniões, mas também intensificando manifestações de antagonismo entre usuários. Nesse contexto, a identificação automática de conflitos em interações textuais representa um desafio relevante para o Processamento de Linguagem Natural, especialmente quando o conflito depende da relação estabelecida entre duas publicações, e não apenas da análise isolada de um texto. Diante desse desafio, este trabalho propôs o desenvolvimento de um conjunto de dados anotado quanto à presença ou ausência de conflito em pares de publicações de rede social e de um modelo baseado em aprendizado profundo para a detecção automática de conflitos em pares de textos em língua portuguesa. O *corpus* foi composto por 3572 pares de publicações da plataforma X, utilizados no treinamento e na avaliação de um modelo BERTimbau ajustado para a tarefa de classificação binária entre *conflito* e *não conflito*. Na avaliação experimental, o modelo alcançou 0,83 de acurácia e F1-score ponderado de 0,84, enquanto, para a classe de *conflito*, obteve F1-score de 0,65, apresentando tanto o potencial de modelos de linguagem contextualizados para essa tarefa quanto os desafios inerentes à identificação automática de interações conflituosas em redes sociais. Os resultados obtidos sugerem que a abordagem proposta constitui uma alternativa promissora para apoiar estudos e aplicações voltados ao monitoramento de conflitos em ambientes digitais.

Palavras-chave: Processamento de Linguagem Natural. Aprendizado Profundo. Detecção de Conflitos. Redes Sociais. BERTimbau.

ABSTRACT

Social media has become an important space for public debate, fostering the exchange of opinions while also intensifying antagonistic interactions among users. In this context, the automatic detection of conflicts in textual interactions represents a relevant challenge for Natural Language Processing, particularly when conflict depends on the relationship established between two posts rather than on the isolated analysis of a single text. To address this challenge, this study proposed the development of an annotated dataset indicating the presence or absence of conflict in pairs of social media posts, as well as a deep learning-based model for the automatic detection of conflicts in pairs of texts written in Brazilian Portuguese. The corpus comprised 3572 pairs of posts collected from the X platform and was used to train and evaluate a fine-tuned BERTimbau model for the binary classification task of conflict versus non-conflict. In the experimental evaluation, the model achieved an accuracy of 0,83 and a weighted F1-score of 0,84. For the conflict class, it obtained an F1-score of 0,65, demonstrating both the potential of contextualized language models for this task and the inherent challenges of automatically identifying conflict in social media interactions. The results suggest that the proposed approach constitutes a promising alternative for supporting studies and applications aimed at monitoring conflicts in digital environments.

Keywords: Natural Language Processing. Deep Learning. Conflict Detection. Social Media. BERTimbau.

LISTA DE ILUSTRAÇÕES

Esquema 1 - Representação do processo modular de uma ferramenta de PLN.....	20
Esquema 2 - Representação das etapas de uma ferramenta de PLN.....	21
Esquema 3 - Representação de entrada utilizada pelo BERT.....	26
Esquema 4: Ajuste fino do BERT.....	28
Esquema 5 - Organização dos datasets iniciais.....	34
Matriz de confusão 1 - Desempenho do modelo no conjunto de teste.....	62

LISTA DE TABELAS

Tabela 1 – Informações gerais dos conjuntos de dados selecionados.....	32
Tabela 2 - Quantidade de publicações disponíveis após o pré-processamento dos dados.....	43
Tabela 3 - Quantidade de pares formados para anotação com os dados pré-processados.....	44
Tabela 4 - Quantidade de dados anotados por tema em cada Etapa.....	44
Tabela 5 - Quantidade de Convergências e Divergências por tema em cada Etapa.....	45
Tabela 6 - Estatísticas dos pares homologados.....	46
Tabela 7 - Distribuição temática das anotações do corpus.....	48
Tabela 8 - Distribuição de anotações do corpus por classe de Tweet.....	52
Tabela 9 - Divisão dos dados por Etapa de anotação.....	55
Tabela 10 - Distribuição final dos dados.....	56
Tabela 11 - Métricas obtidas em cada época de treinamento.....	56
Tabela 12 – Evolução das métricas da classe conflito durante o treinamento.....	58
Tabela 13 – Desempenho do modelo no conjunto de teste.....	60
Tabela 14 - Desempenho das estratégias de mitigação do desbalanceamento.....	61
Tabela 15 – Distribuição dos conflitos e dos falsos negativos por tema.....	63
Tabela 16 – Certeza Média de Não Conflito dos falsos negativos por tema.....	63
Tabela 17 – Distribuição dos conflitos e falsos negativos por tipo de interação.....	64
Tabela 18 – Quantidade de ocorrências dos motivos para os falsos negativos.....	65

LISTA DE GRÁFICOS

Gráfico 1 - Crescimento da quantidade de dados armazenados na internet.....	19
Gráfico 2 - Distribuição dos rótulos ao longo das etapas.....	47
Gráfico 3 - Distribuição dos rótulos ao longo dos grupos temáticos da Etapa 1.....	49
Gráfico 4 - Distribuição dos rótulos ao longo dos grupos temáticos da Etapa 2.....	50
Gráfico 5 - Distribuição dos rótulos ao longo dos grupos temáticos da Etapa 3.....	50
Gráfico 6 - Distribuição dos rótulos por tema no corpus final.....	51
Gráfico 7 - Percentual de conflitos por classe de tweet e etapa de anotação.....	54
Gráfico 8 - Distribuição de conflitos por classe de tweet no Dataset final.....	54
Gráfico 9 - Evolução das funções de perda durante o treinamento.....	57
Gráfico 10 - Evolução das principais métricas de avaliação durante o treinamento.....	58
Gráfico 11 - Evolução das métricas da classe conflito durante o treinamento.....	59

LISTA DE ABREVIATURAS E SIGLAS

- API — Interface de Programação de Aplicações (*Application Programming Interface*)
- BERT — *Bidirectional Encoder Representations from Transformers*
- BiLSTM - Memória de Longo e Curto Prazo Bidirecional (*Bidirectional Long Short-Term Memory*)
- CLS — *Classification Token*
- ELMo — *Embeddings from Language Models*
- GPT — *Generative Pre-trained Transformer*
- GPU — Unidade de Processamento Gráfico (*Graphics Processing Unit*)
- GRU — Unidade Recorrente Fechada (*Gated Recurrent Unit*)
- LSTM — Memória de Longo e Curto Prazo (*Long Short-Term Memory*)
- MLM — *Masked Language Modeling*
- mBERT — *Multilingual BERT*
- NSP — *Next Sentence Prediction*
- PLN — Processamento de Linguagem Natural
- RNN — Redes Neurais Recorrentes (*Recurrent Neural Networks*)
- RSD — Redes Sociais Digitais
- SEP — *Separator Token*
- TRAC — *Trolling, Aggression and Cyberbullying* (competição)
- X — Plataforma X (antigo Twitter)

SUMÁRIO

1 INTRODUÇÃO.....	13
2 OBJETIVOS.....	15
3 FUNDAMENTAÇÃO TEÓRICA.....	16
3.1 Redes sociais e o estudo computacional da linguagem.....	16
3.2 Conflitos em interações textuais.....	17
3.3 Processamento de Linguagem Natural.....	19
3.4 Fundamentos de Aprendizado de Máquina e Modelos Pré-treinados.....	21
3.5 Transformers.....	23
3.6 Arquitetura BERT.....	24
3.6.1 Visão geral da estrutura.....	25
3.6.2 Representação da entrada (input embeddings).....	25
3.6.3 Representação Bidirecional.....	27
3.6.4 Pré-Treinamento.....	27
3.6.5 Ajuste fino para Classificação.....	28
3.7 Modelo BERTimbau.....	29
3.8 Trabalhos relacionados.....	30
4 MATERIAIS E MÉTODOS.....	32
4.1 Construção do corpus.....	32
4.1.1 Origem dos dados.....	32
4.1.2 Preparação e organização dos dados.....	33
4.1.3 Geração de pares e amostragem aleatória.....	34
4.1.4 Critérios e mecânica de anotação.....	35
4.1.5 Estratégia de anotação em múltiplas etapas.....	36
4.2 Processo de ajuste fino do classificador.....	37
4.2.1 Modelo base.....	37
4.2.2 Divisão dos dados.....	38
4.2.3 Pré-processamento dos dados.....	39
4.2.4 Treinamento do modelo.....	39
4.2.5 Ambiente computacional.....	41
4.2.6 Estratégias para mitigação do desbalanceamento de classes.....	41
4.3 Estratégia de avaliação.....	42
5 RESULTADOS E DISCUSSÕES.....	43
5.1 Resultados do processo de anotação.....	43
5.1.1 Estatísticas dos dados coletados e pré-processados.....	43
5.1.2 Estatísticas do processo de anotação.....	44
5.1.3 Evolução do corpus anotado ao longo das etapas.....	46
5.1.4 Distribuição temática do corpus.....	48
5.1.5 Distribuição por classe do corpus.....	52
5.2 Resultados do modelo especializado.....	55
5.2.1 Divisão dos dados de treino e teste.....	55
5.2.2 Evolução do modelo durante o ajuste fino.....	56
5.2.3 Avaliação do modelo treinado.....	60
5.2.4 Comparativo das estratégias de mitigação do desbalanceamento.....	61

5.2.5 Análise quantitativa dos erros.....	62
5.2.6 Caracterização dos falsos negativos.....	64
6 DISCUSSÃO.....	68
7 CONCLUSÃO.....	70
REFERÊNCIAS.....	72

1 INTRODUÇÃO

As redes sociais transformaram profundamente a forma como indivíduos produzem, compartilham e consomem informações, estabelecendo novos modelos de comunicação caracterizados pela rapidez, ampla conectividade e ausência de barreiras geográficas ou temporais [1]. Diferentemente dos meios tradicionais de comunicação, essas plataformas permitem que qualquer usuário produza conteúdo e participe ativamente de discussões públicas, favorecendo assim uma comunicação descentralizada e contínua [2,3]. Essas características ampliaram significativamente as possibilidades de participação social, oferecendo um ecossistema oportuno ao engajamento dos usuários em debates públicos, a organização de movimentos coletivos e a circulação de diferentes perspectivas sobre questões de interesse social e político [3,4]. Como consequência, as redes sociais consolidaram-se como uma via primária para a comunicação interpessoal [5,6] e como importantes espaços para a construção da opinião pública e para o exercício da cidadania em ambientes digitais [3,4].

Entretanto, as mesmas características que favorecem a democratização da comunicação também tornam esses ambientes propícios ao surgimento de desacordos, polarização e diferentes formas de antagonismo entre usuários [2]. A facilidade de publicação e a elevada velocidade de disseminação das mensagens, somadas à interação entre indivíduos com diferentes valores e crenças e à redução das barreiras sociais típicas das interações presenciais, contribuem para a intensificação de debates e conflitos em plataformas digitais [1,2]. Além disso, a liberdade oferecida por esse ecossistema aberto propicia a circulação de conteúdos potencialmente inadequados e ofensivos [7], nos quais interações cotidianas escalam para discursos de ódio, misoginia e agressividade verbal [7,8]. Diante do impacto que este meio produz sobre o comportamento dos indivíduos e a sociedade contemporânea, torna-se essencial compreender e monitorar a dinâmica de tais interações [1].

A identificação de conflitos e discursos de ódio em redes sociais, embora essencial para a proteção dos usuários nesses espaços, representa um desafio que tem levado empresas de mídia social e órgãos governamentais a investirem no desenvolvimento de sistemas automatizados capazes de realizar essa tarefa com maior eficiência [7,8]. Para responder a essa demanda, o campo do Processamento de Linguagem Natural (PLN) tem desempenhado um papel fundamental, ao oferecer-se como terreno fértil para o desenvolvimento de modelos computacionais e algoritmos avançados capazes de capturar o amplo espectro dos conflitos

em redes sociais [5,7], ou classificar e detectar manifestações agressivas com maior eficiência [8]. Entretanto, a identificação automática de conflitos entre interações textuais permanece menos explorada, especialmente quando considerada como um fenômeno discursivo que depende da relação estabelecida entre duas publicações, e não apenas das características isoladas de um único texto [5,9].

Diante desse contexto, este trabalho propõe o desenvolvimento de um sistema de detecção de conflitos em publicações de redes sociais. Para isso, foi construído um *corpus* anotado de pares de tweets em língua portuguesa, com base em uma definição de conflito derivada da literatura especializada, sendo posteriormente expandido ao longo de sucessivas etapas de anotação. Esse *corpus* foi utilizado no treinamento e na avaliação de um modelo baseado na arquitetura BERT (*Bidirectional Encoder Representations from Transformers*), permitindo investigar a viabilidade da classificação automática de interações conflituosas entre pares de publicações. Os resultados obtidos indicaram que, apesar das limitações de desempenho, o modelo foi capaz de aprender padrões relacionados às interações conflituosas, demonstrando que abordagens baseadas em modelos de linguagem contextualizados são promissoras para a análise de conflitos em redes sociais apesar dos desafios inerentes à tarefa.

O restante deste texto está organizado da seguinte forma: a Seção 2 apresenta os objetivos da pesquisa, delineando a proposta desenvolvida, o objetivo geral e os objetivos específicos que norteiam o estudo. A Seção 3 apresenta o referencial teórico, abordando os principais conceitos relacionados às redes sociais, à caracterização de conflitos em textos e às técnicas de Processamento de Linguagem Natural, incluindo modelos baseados em Transformers e BERT. A Seção 4 descreve os materiais e métodos empregados, contemplando a construção do conjunto de dados anotado, o desenvolvimento do modelo e a metodologia experimental adotada. A Seção 5 apresenta os resultados obtidos a partir dos experimentos realizados. A Seção 6 discute os resultados, relacionando-os aos objetivos propostos e as limitações observadas. Por fim, a Seção 7 reúne as conclusões do trabalho e sugestões para pesquisas futuras.

2 OBJETIVOS

Este trabalho teve como objetivo geral investigar a viabilidade da detecção automática de conflitos em publicações de redes sociais utilizando um modelo de linguagem pré-treinado baseado na arquitetura Transformer. Para tanto, estabeleceram-se os seguintes objetivos específicos:

- Definir critérios operacionais para a identificação de conflitos em interações textuais;
- Construir e validar um *corpus* anotado em língua portuguesa, composto por pares de tweets categorizados quanto à presença ou ausência de conflito;
- Especializar um modelo de aprendizado profundo baseado em Transformers para a classificação automática de conflitos em pares de textos;
- Avaliar o desempenho preditivo do modelo na detecção de interações conflituosas.

3 FUNDAMENTAÇÃO TEÓRICA

Este capítulo reúne os fundamentos teóricos que embasam o desenvolvimento deste trabalho. São apresentados conceitos relacionados ao contexto das interações em redes sociais, aos fundamentos computacionais empregados na detecção automática de conflitos em textos e aos principais trabalhos relacionados à temática investigada.

3.1 Redes sociais e o estudo computacional da linguagem

As Redes Sociais Digitais (RSDs) consistem em plataformas virtuais que possibilitam a criação, o compartilhamento e a circulação contínua de conteúdos produzidos pelos próprios usuários, estabelecendo ambientes caracterizados por elevada conectividade e interação em tempo real [1]. Estruturalmente, essas plataformas podem ser compreendidas como arquiteturas compostas por atores sociais e pelas conexões estabelecidas entre eles, nas quais as interações constituem o principal mecanismo de formação e fortalecimento dessas relações [10]. Essa dinâmica distingue as RSDs dos meios tradicionais de comunicação, ao permitir que os próprios usuários atuem simultaneamente como produtores, consumidores e disseminadores de conteúdo em um modelo de comunicação descentralizado e baseado na participação ativa dos indivíduos [1,2].

As interações estabelecidas nesses ambientes apresentam características que as diferenciam da comunicação presencial. Conforme discutido por Recuero [10], as conexões entre os atores são estabelecidas por meio das interações realizadas nas plataformas digitais, as quais apresentam características próprias, como a possibilidade de ocorrerem de forma assíncrona, a ausência de restrições geográficas e a organização das conversações por mecanismos específicos das plataformas [1,2]. Além disso, a redução de elementos não verbais, como gestos, expressões faciais e entonação, faz com que a interpretação das mensagens dependa principalmente do conteúdo textual e do contexto discursivo em que a interação ocorre [10].

Essas características tornam as redes sociais um ambiente particularmente relevante para o estudo computacional da linguagem. O elevado volume de conteúdo textual produzido diariamente, aliado à disponibilidade de informações estruturadas sobre as interações entre usuários, fornece uma fonte expressiva de dados para pesquisas em áreas como Ciência da Computação, PLN e Mineração de Dados [6,11]. Em 2023, estimava-se a existência de

aproximadamente 4,8 bilhões de usuários ativos em redes sociais em todo o mundo, correspondendo a cerca de 60% da população mundial e produzindo continuamente grandes volumes de conteúdo digital [6].

Entre as diversas plataformas de redes sociais, a plataforma X (antigo *Twitter*) destaca-se por disponibilizar, além do conteúdo textual das publicações, uma estrutura de metadados que descreve atributos dos *tweets* e suas relações com outras mensagens [12]. Os *tweets* são publicações que podem conter texto, imagens, GIFs, vídeos e links, sendo o conteúdo textual limitado a até 280 caracteres [13]. Os metadados associados aos *tweets* incluem informações como autoria, data de publicação e referências estruturais entre *tweets*, permitindo identificar diferentes formas de interação entre usuários [12]. Historicamente, a disponibilização dessas informações por meio da antiga Interface de Programação de Aplicações (API) da plataforma consolidou o X como uma das principais fontes de dados para pesquisas em PLN, especialmente em tarefas relacionadas à análise de opiniões, sentimentos, comportamento social e interações discursivas [9,11]. Em 2023, mudanças na API do X restringiram o acesso gratuito aos dados da plataforma, exigindo que pesquisadores passassem a utilizar versões pagas ou adaptassem seus processos de coleta de dados. Essas alterações tendem a impactar a construção de novos *corpus* e o desenvolvimento de pesquisas que utilizam dados provenientes dessa rede social [13].

Sob a perspectiva do campo de PLN, as relações estruturais disponibilizadas pela plataforma, como respostas (*replies*) e citações (*quotes*), permitem recuperar informações de contexto entre publicações relacionadas. Em determinadas tarefas de análise textual, a análise conjunta de publicações relacionadas pode fornecer informações que não seriam obtidas pela análise isolada de um único texto, uma vez que informações relevantes para a compreensão do fenômeno investigado podem não estar presentes no texto de forma isolada [9]. Motivado por essa perspectiva, este trabalho baseia a construção do *corpus* em pares de *tweets* como unidade de análise para investigar a detecção automática de conflitos em interações textuais.

3.2 Conflitos em interações textuais

A busca por uma definição de conflito trata-se de um desafio recorrente na literatura, não havendo um consenso universal sobre o seu significado. Segundo Lyamouri-Bajja et al. [14], o conceito de conflito tem sido abordado sob diferentes perspectivas ao longo do tempo, variando em função do contexto histórico e social em que é analisado. Ainda segundo os

autores, algumas definições concentram-se nas causas do conflito, como disputas por poder, divergências de valores ou fatores emocionais, enquanto outras focam na natureza dos atores envolvidos, sejam indivíduos, grupos ou organizações. Essa diversidade de abordagens deixa claro que o conflito não é um fenômeno unidimensional, mas sim um conceito que depende do contexto em que é analisado. Nesse sentido faz-se necessária uma operacionalização de sua definição a partir de recortes específicos, visando adaptar-se aos objetivos e ao domínio de aplicação do estudo.

No contexto de mídias sociais, essa necessidade se intensifica, dado a natureza dinâmica e linguagem característica dessas interações. Segundo Cabral e Guaranha [2], esses ambientes se consolidaram como espaços de debate público nos quais usuários expõem posicionamentos, defendem opiniões e participam de controvérsias, frequentemente marcadas por forte polarização e violência verbal. Os autores argumentam que a ampla visibilidade das interações, aliada à possibilidade de anonimato ou construção de identidades idealizadas, favorece a intensificação de conflitos e de manifestações discursivas agressivas.

Warke et. al. [5], em um estudo com objetivos semelhantes ao do presente trabalho, apontam que a abordagem predominante na detecção de conflitos em textos tende a se concentrar na identificação de manifestações explicitamente antagônicas, isto é, situações em que há oposição clara entre os participantes. No entanto, o mesmo estudo propõe uma visão mais abrangente do fenômeno buscando capturar o espectro do conflito. Nessa abordagem, os autores se baseiam em um estudo de análise de caráter netnográfico sobre interações em plataformas sociais, no qual são identificados diferentes categorias associadas ao conflito, são elas: *provocação, crítica, sarcasmo, trolling, assédio e ameaças*.

Essa perspectiva é compatível com os estudos de Cabral e Guaranha [2], que observam que, em discussões polêmicas nas redes sociais, o conflito frequentemente se manifesta por meio de estratégias discursivas como insultos, desqualificação do interlocutor e linguagem agressiva. Além disso, os autores mostram que essas manifestações não têm apenas a função de atacar o oponente, mas também de reforçar posicionamentos e identidades de grupo, contribuindo para a intensificação da polarização nas interações digitais.


Diante dessas considerações, este trabalho define *conflito*, no contexto de mídias sociais, como *manifestações discursivas antagônicas em uma interação, incluindo formas mais sutis, como provocação, crítica e sarcasmo, e formas mais hostis, como assédio e ameaças*.

Essa definição permite capturar não apenas conflitos explícitos, mas também formas sutis de antagonismo, sendo adequada ao objetivo deste trabalho de analisar relações discursivas entre pares de tweets.

3.3 Processamento de Linguagem Natural

A linguagem é um dos aspectos fundamentais do comportamento humano e constitui um componente essencial da vida em sociedade [15]. É por meio dela que aumentamos nossa capacidade de nos comunicar, relacionar, transmitir e registrar informações e conhecimentos por gerações. Com a evolução das redes sociais e sua capacidade de permitir que todos os usuários sejam capazes de registrar e compartilhar conteúdo por meio da linguagem, notamos a quantidade massiva de dados que são gerados nessas redes, e na internet como um todo, crescendo ano a ano em ritmo exponencial, como ilustra o Gráfico 1. Apesar dessa produção massiva de dados, uma porção predominante, correspondente a cerca de 99,5%, não é utilizada de forma analítica [16].

Gráfico 1 - Crescimento da quantidade de dados armazenados na internet



Fonte: ADEC Group 2014 [17]

Para que esse grande recorte da comunicação humana não se perca e possamos entender melhor como se dão nossas interações, incluindo as conflituosas, evidencia-se a necessidade de se desenvolver métodos capazes de analisar esses dados. Como esses dados são produzidos e transmitidos por meio da linguagem, é necessário que esse método seja capaz de compreendê-la.


O Processamento de Linguagem Natural (PLN) é o nome que se dá à área de pesquisa que se dedica a investigar, propor e desenvolver formalismos, modelos, técnicas, métodos e sistemas computacionais que têm a língua natural como objeto primário [18]. De modo geral, em PLN buscam-se soluções para problemas computacionais, ou seja, tarefas, sistemas, aplicações ou programas, que requerem o tratamento computacional de uma língua natural, quer seja escrita ou falada [18].

Para tanto, o sistema de linguagem natural deve usar conhecimento considerável sobre estrutura da linguagem em si, buscando compreender, dentre eles, a *fonética* e *fonologia*, entendendo como as palavras se relacionam com os sons que elas fazem, a *morfologia*, que compreende como as palavras são construídas a partir de unidades de significado mais básico, a *sintaxe*, com a ordenação das palavras em uma mesma sentença, e *semântica*, representando o que as palavras significam e como esses significados se combinam nas frases para formar significados de sentenças. Por fim, em alguns casos é importante que o sistema possua conhecimentos contextuais, com a *pragmática*, analisando como sentenças são usadas em diferentes situações e como esse uso afeta a interpretação da sentença, o *discurso*, como a sentença imediatamente precedente afeta a interpretação da próxima, e conhecimentos gerais sobre a estrutura do mundo que os usuários da linguagem devem ter para, por exemplo, manter uma conversa, assim como o que cada usuário da linguagem deve saber sobre as crenças e objetivos do outro usuário.

Junto disso, são necessários recursos linguísticos-computacionais, como o *corpus* textual, um conjunto de textos organizados para estudos da linguagem, que podem ser anotados ou não. Esse conjunto de dados textuais é utilizado no treinamento de ferramentas de PLN, permitindo que elas capturem padrões textuais e linguísticos presentes nos dados.


As aplicações de PLN são construídas de maneira modular a partir de uma ou mais tarefas computacionais sequenciais, em que cada tarefa recebe uma entrada e devolve uma saída, sendo a saída de um módulo a entrada do módulo subsequente.

Esquema 1 - Representação do processo modular de uma ferramenta de PLN



Fonte: Ahmad et al. [19]

Esquema 2 - Representação das etapas de uma ferramenta de PLN



Fonte: Allen J. [15]

Essas aplicações podem ser divididas em duas classes majoritárias: as aplicações baseadas em diálogos e as aplicações baseadas em texto [15]. Aplicações baseadas em diálogo envolvem interações homem-máquina, seja por meio da linguagem falada ou do uso de teclados, e dentre elas, destacam-se sistemas de pergunta-resposta e assistente de voz. As aplicações baseadas em texto representam a classe de interesse deste trabalho, que envolve o processamento de texto escrito, como nas postagens nas redes sociais, livros, jornais, manuais, mensagens de e-mail, e outros, sendo que todos esses envolvem tarefas baseadas em leitura [15]. Dentre essas aplicações destacam-se a categorização e resumo de textos, detecção de tipos de conteúdos específicos como *fake news*, *spam* em e-mails ou discurso de ódio, e a própria análise de sentimentos, o que justifica sua utilização neste trabalho para a detecção de conflitos em interações nas redes sociais.

3.4 Fundamentos de Aprendizado de Máquina e Modelos Pré-treinados

O desenvolvimento das abordagens modernas de PLN está diretamente relacionado à evolução das técnicas de aprendizado de máquina e, posteriormente, ao surgimento do *aprendizado profundo* e do *aprendizado por transferência*. Segundo Jordan e Mitchell [20], o

aprendizado de máquina (*Machine Learning*) consiste em um conjunto de métodos computacionais capazes de identificar padrões em dados e utilizá-los para realizar previsões ou tomadas de decisão de forma autônoma. Entre seus diferentes paradigmas, destaca-se o *aprendizado supervisionado*, no qual o modelo é treinado a partir de exemplos previamente associados às suas respectivas respostas esperadas, permitindo aprender uma relação entre os dados de entrada e suas saídas para posteriormente realizar predições sobre novos exemplos [20].

No contexto deste trabalho, a tarefa de detecção de conflitos em textos corresponde a um problema de *classificação supervisionada*, no qual o modelo recebe exemplos textuais previamente rotulados e aprende padrões associados às diferentes classes de interesse. Entretanto, devido à complexidade inerente à linguagem natural, marcada por ambiguidades, variações de expressão e dependência de contexto, a modelagem desse tipo de dado demanda abordagens capazes de extrair automaticamente informações relevantes dos textos, motivando o uso de técnicas de *aprendizado profundo* (*Deep Learning*).

O *aprendizado profundo* corresponde a uma subárea do aprendizado de máquina baseada em redes neurais artificiais compostas por múltiplas camadas de processamento [21]. Diferentemente de abordagens que dependem da definição manual de atributos, essas arquiteturas identificam automaticamente padrões relevantes diretamente dos dados, refinando essas informações em diferentes camadas da rede durante o treinamento [21]. Em PLN, essa capacidade possibilitou avanços na construção de modelos capazes de aprender representações linguísticas diretamente a partir de grandes volumes de texto. Dessa forma, características relevantes da linguagem passaram a ser aprendidas pelo próprio modelo, reduzindo a necessidade de criação manual de atributos linguísticos específicos para cada tarefa [22].

Contudo, embora essas arquiteturas sejam capazes de aprender automaticamente representações linguísticas, a qualidade dessas representações depende da disponibilidade de grandes volumes de dados de treinamento [22]. Além disso, em abordagens convencionais, essas representações precisam ser aprendidas novamente para cada nova tarefa de PLN. Considerando que muitos dos padrões e características da linguagem são compartilhados entre diferentes aplicações, tornou-se vantajoso aprender representações linguísticas gerais uma única vez a partir de grandes volumes de texto e reutilizá-las em tarefas distintas, em vez de reaprender essas características para cada problema específico [22].

Essa ideia fundamenta o *aprendizado por transferência* (*transfer learning*), no qual um modelo inicialmente treinado em grandes conjuntos de dados pode ter o conhecimento

adquirido adaptado para tarefas específicas [22]. Em PLN, esse paradigma tornou-se amplamente utilizado por meio de modelos de linguagem pré-treinados, que aprendem representações gerais da linguagem durante o pré-treinamento e posteriormente são ajustados para aplicações específicas por meio do processo de *ajuste fino* (*fine-tuning*) [22]. Esse paradigma estabeleceu a base para o desenvolvimento dos modelos modernos de linguagem pré-treinados, que passaram a representar o estado da arte em diversas tarefas de PLN [22]. Entre esses modelos, destacam-se aqueles baseados na arquitetura Transformer, apresentada na seção seguinte.

3.5 Transformers

Até meados da década de 2010, os modelos predominantes no campo de PLN eram baseados em *redes neurais recorrentes* (*Recurrent Neural Networks* – RNN) e suas variações, como *Long Short-Term Memory* (LSTM) e *Gated Recurrent Unit* (GRU). Embora esses modelos tenham representado um avanço em relação às abordagens tradicionais baseadas em regras e características manuais, sua natureza sequencial dificultava o processamento paralelo dos dados e limitava a capacidade de capturar dependências entre palavras muito distantes em um texto [23].

Em resposta às dificuldades associadas ao processamento sequencial das RNNs, Vaswani et al. [23] propuseram a arquitetura Transformer, baseada exclusivamente em mecanismos de atenção e sem utilizar estruturas recorrentes ou convolucionais. Estruturalmente, o modelo original segue uma arquitetura *codificador-decodificador* (*encoder-decoder*), na qual tanto o codificador quanto o decodificador são compostos por camadas de autoatenção e redes neurais *feed-forward*. O codificador é responsável por processar toda a sequência de entrada, produzindo representações contextualizadas. O decodificador, por sua vez, utiliza essas representações para construir a sequência de saída de maneira incremental, gerando um elemento por vez com base no contexto da entrada e nos elementos já produzidos. O funcionamento desta arquitetura é fundamentado no mecanismo de autoatenção (*self-attention*), que permite que cada elemento da sequência seja representado considerando simultaneamente todos os demais elementos da entrada, favorecendo a modelagem de dependências de longo alcance sem a necessidade de processamento estritamente sequencial [23].

Essa arquitetura representou um avanço significativo para o campo de PLN, permitindo sua aplicação em uma ampla variedade de tarefas, incluindo classificação de textos, análise de sentimentos, reconhecimento de entidades nomeadas, resposta a perguntas e inferência textual [22,24]. Além de favorecer o processamento paralelo e a modelagem de dependências de longo alcance, os Transformers impulsionaram o desenvolvimento de modelos de linguagem pré-treinados, que empregam um processo de pré-treinamento seguido de ajuste fino (*fine-tuning*) e alcançaram resultados de estado da arte em diversos *benchmarks* de PLN [22,24,25].

Atualmente, os Transformers constituem a arquitetura predominante no desenvolvimento de modelos de linguagem utilizados em aplicações de PLN, sendo empregados tanto em tarefas clássicas de classificação textual quanto em modelos generativos de grande escala [22]. Entre os diversos modelos desenvolvidos a partir dessa arquitetura, destaca-se o BERT, adotado neste trabalho e apresentado na Seção seguinte.

3.6 Arquitetura BERT

O *Bidirectional Encoder Representations from Transformers* (BERT) é um modelo de linguagem baseado na arquitetura Transformer desenvolvido para gerar representações contextuais profundas e bidirecionais a partir de grandes volumes de texto não rotulado [25]. Diferentemente de modelos anteriores que processavam sequências textuais de forma unidirecional (da direita para a esquerda ou da esquerda para a direita), o BERT foi projetado para aprender representações considerando simultaneamente os contextos à esquerda e à direita de cada palavra em todas as camadas da rede [25]. Essa característica permite que a representação de um termo seja construída a partir de todo o contexto em que ele aparece, produzindo representações linguísticas mais contextualizadas do que aquelas obtidas por *embeddings* estáticos ou modelos unidirecionais [24,25]. Como resultado, o modelo pode ser pré-treinado em grandes *corpora* textuais e posteriormente adaptado para diferentes tarefas de PLN por meio de um processo de ajuste fino (*fine-tuning*) [25].

As principais características estruturais do modelo são detalhadas nas Seções seguintes.

3.6.1 Visão geral da estrutura

A estrutura interna do BERT é baseada na arquitetura Transformer proposta por Vaswani et al. (2017), utilizando exclusivamente a porção codificadora (*Encoder*) da arquitetura original [25]. O modelo é formado por diversas camadas empilhadas, cada uma composta por mecanismos de autoatenção (*self-attention*) e redes neurais *feed-forward*. Essas camadas trabalham em conjunto para construir representações contextuais cada vez mais ricas dos textos de entrada [25].

Por meio do mecanismo de autoatenção, a representação de cada *token* é calculada com base nos demais *tokens* da sequência, permitindo a captura de relações contextuais entre palavras independentemente de sua distância no texto [25]. Além disso, a arquitetura possibilita o processamento paralelo das entradas, diferentemente das abordagens recorrentes tradicionalmente utilizadas em tarefas de PLN [25].

No artigo que apresentou o modelo, Devlin et al. [25] especificaram duas configurações principais para sua aplicação:

- BERT Base: possui 12 camadas de codificadores ($L=12$), dimensão oculta de 768 unidades ($H=768$) e 12 cabeças de atenção ($A=12$), totalizando aproximadamente 110 milhões de parâmetros.
- BERT Large: possui 24 camadas de codificadores ($L=24$), dimensão oculta de 1024 unidades ($H=1024$) e 16 cabeças de atenção ($A=16$), totalizando aproximadamente 340 milhões de parâmetros.

Segundo Devlin et al. [25], a configuração BERT Base foi definida de forma comparável ao modelo OpenAI GPT, enquanto a configuração BERT Large foi desenvolvida com uma quantidade substancialmente maior de parâmetros. Nos experimentos apresentados pelos autores, o BERT Large obteve desempenho superior ao BERT Base em diversas tarefas de PLN avaliadas.

3.6.2 Representação da entrada (*input embeddings*)


Antes de ser processado pelo modelo, o texto de entrada é convertido em uma sequência de *tokens*. O BERT possui uma representação de entrada flexível, capaz de receber tanto uma única sentença quanto um par de sentenças em uma mesma sequência de entrada

[25]. Para isso, a representação de entrada é composta formalmente por três tipos distintos de *embeddings* [25]:

- *Token Embeddings*: os textos são inicialmente divididos em unidades menores chamadas *tokens* por meio do *tokenizador* WordPiece utilizado pelo modelo [25].
- *Segment Embeddings*: Trata-se de uma sequência vetorial utilizada para indicar a qual sentença cada *token* pertence quando a entrada é composta por um par de sentenças. Nesse caso, os *tokens* são identificados como pertencentes à Sentença A ou à Sentença B [25].
- *Position Embeddings*: São vetores adicionados para codificar a posição de cada *token* dentro da sequência de entrada. Essa informação é necessária porque a arquitetura Transformer não possui mecanismos recorrentes capazes de representar naturalmente a ordem sequencial dos elementos [25].

Além desses componentes, o BERT utiliza dois tokens especiais para estruturar suas entradas. O *token* [CLS] é inserido obrigatoriamente no início da sequência e sua representação final pode ser utilizada em tarefas de classificação. Já o token [SEP] é utilizado para separar sentenças distintas ou indicar o término da sequência de entrada [25]. O esquema 3 apresenta a representação de entrada utilizada pelo BERT, ilustrando a combinação dos diferentes *embeddings* e a utilização dos tokens especiais na organização das sequências processadas pelo modelo.

Esquema 3 - Representação de entrada utilizada pelo BERT



Fonte: Devlin et al. [25]

A soma vetorial dos *Token Embeddings*, *Segment Embeddings* e *Position Embeddings* produz a representação final utilizada como entrada para as camadas codificadoras do modelo [25].

3.6.3 Representação Bidirecional

Uma das principais contribuições do BERT é a utilização de representações contextuais bidirecionais. Diferentemente de abordagens anteriores, que aprendiam a representação das palavras considerando apenas o contexto anterior ou combinavam posteriormente representações obtidas em cada direção da sequência, o BERT aprende simultaneamente a partir dos contextos precedente e subsequente durante o pré-treinamento, permitindo construir representações mais contextualizadas para cada *token* [25].

Essa estratégia possibilita que a interpretação de uma palavra seja influenciada por todo o contexto em que ela está inserida, favorecendo a modelagem de relações sintáticas e semânticas mais complexas. Segundo Devlin et al. [25], a capacidade de gerar representações profundamente bidirecionais contribuiu para o desempenho do BERT em diversas tarefas de Processamento de Linguagem Natural. Rogers et al. [24] destacam ainda que essas representações capturam diferentes níveis de informação linguística, contribuindo para a adaptação do modelo a tarefas específicas por meio do ajuste fino.

No âmbito deste trabalho, a capacidade de gerar representações bidirecionais mostra-se fundamental para a tarefa de detecção de conflitos em pares de tweets. Uma vez que a caracterização do conflito raramente se resume à presença de termos agressivos isolados, mas sim da relação discursiva e dependência contextual entre a publicação original e sua resposta ou citação, o processamento simultâneo de todo o contexto em ambas as direções permite ao modelo apreender sutilezas semânticas que seriam ignoradas por abordagens unidirecionais. Assim, a arquitetura do BERT fornece a base necessária para capturar o conflito como uma troca entre usuários que só se revela no conjunto da conversa.

3.6.4 Pré-Treinamento

O treinamento do modelo BERT é dividido em duas etapas principais: o pré-treinamento e o ajuste fino (*fine-tuning*) [25]. Na etapa de pré-treinamento, o modelo é exposto a grandes *corpora* de texto não rotulado com o objetivo de aprender representações

linguísticas que possam ser posteriormente transferidas para diferentes tarefas de Processamento de Linguagem Natural [25].

Durante o pré-treinamento, Devlin et al. [25] propuseram duas tarefas principais: *Masked Language Model* (MLM) e *Next Sentence Prediction* (NSP). A tarefa MLM foi desenvolvida para possibilitar o aprendizado bidirecional, na qual parte dos *tokens* de uma sequência de entrada é ocultada e o modelo deve recuperá-los considerando simultaneamente os contextos à esquerda e à direita da posição analisada. Essa estratégia permite que o BERT aprenda relações entre palavras considerando toda a sequência de entrada.


A segunda tarefa de pré-treinamento, denominada NSP, consiste em receber pares de sentenças e identificar se a segunda sentença corresponde à continuação da primeira no texto original [25]. Essa tarefa auxilia o aprendizado de relações entre diferentes segmentos textuais, contribuindo para tarefas que dependem da compreensão de múltiplas sentenças.

A combinação entre as tarefas MLM e NSP constitui a base para a construção das representações contextuais do BERT, posteriormente utilizadas no ajuste fino para tarefas específicas [24,25].

3.6.5 Ajuste fino para Classificação

Após o pré-treinamento em grandes volumes de texto não rotulado, o BERT pode ser adaptado para tarefas específicas por meio do processo de ajuste fino (*fine-tuning*) [25]. Nessa etapa, os parâmetros aprendidos durante o pré-treinamento são utilizados como ponto de partida e ajustados utilizando conjuntos de dados rotulados da tarefa de interesse.

Esquema 4: Ajuste fino do BERT



Fonte: Devlin et al. [25]

Segundo Devlin et al. [25], o processo de ajuste fino permite que a mesma arquitetura pré-treinada seja adaptada para diferentes tarefas de PLN, exigindo apenas pequenas modificações na camada de saída. Em tarefas de classificação textual, a representação final associada ao token [CLS] é utilizada como representação da sequência completa, sendo conectada a uma camada responsável pela predição da classe desejada [25].

Essa estratégia de pré-treinamento seguido de ajuste fino impulsionou o uso do BERT em tarefas como classificação de textos, análise de sentimentos, inferência textual, reconhecimento de entidades nomeadas, sistemas de perguntas e respostas e, mais recentemente, na detecção de conteúdos ofensivos e comportamentos agressivos em mídias sociais [7,8,25]. A utilização do BERT em problemas relacionados à identificação de conflitos será discutida com maior detalhamento na Seção 3.8.

3.7 Modelo BERTimbau

Embora o BERT tenha sido originalmente desenvolvido para a língua inglesa, Souza et al. [26] propuseram o BERTimbau, uma versão do modelo pré-treinada especificamente para o português brasileiro. O objetivo do trabalho foi desenvolver modelos de linguagem baseados na arquitetura BERT treinados em um grande *corpus* de textos em português, favorecendo a produção de representações linguísticas mais adequadas às particularidades léxicas, sintáticas e morfológicas do idioma [26].

Para o treinamento, os autores utilizaram o *corpus* brWaC (*Brazilian Web as Corpus*), composto por aproximadamente 2,7 bilhões de tokens obtidos de páginas da Web em português do Brasil [26]. O treinamento seguiu a mesma arquitetura e o mesmo procedimento de pré-treinamento adotados pelo BERT original, discutido na Seção 3.6 [25,26].

Assim como no modelo original, foram disponibilizadas duas configurações: BERTimbau Base e BERTimbau Large [26]. Os autores avaliaram ambos os modelos em diferentes tarefas de PLN para o português do Brasil, incluindo reconhecimento de entidades nomeadas, inferência textual e similaridade semântica textual. Os resultados experimentais demonstraram que o BERTimbau superou modelos multilíngues previamente utilizados para o português, incluindo o *Multilingual* BERT (mBERT), alcançando resultados superiores nos conjuntos de dados avaliados [26].

Os resultados obtidos por Souza et al. [26] evidenciam o potencial de modelos pré-treinados especificamente para o português do Brasil na construção de representações

linguísticas mais adequadas para tarefas de PLN específicas ao idioma. Por esse motivo, neste trabalho optou-se pela utilização do BERTimbau como modelo base para a tarefa de classificação de conflitos em textos escritos em português.

3.8 Trabalhos relacionados

A identificação automática de conflitos, comportamentos agressivos e conteúdos ofensivos em mídias sociais vem recebendo crescente atenção da comunidade científica, especialmente após a popularização de modelos baseados em Transformers e representações contextuais de linguagem. Devido à sua capacidade de produzir representações linguísticas ricas, diversos estudos têm explorado o uso do BERT e de suas variantes em tarefas relacionadas à classificação de interações hostis, discurso de ódio, agressividade e conflitos em ambientes digitais [5,7,8].

Num trabalho recente, Warke et al. [5] propuseram um modelo voltado para a classificação de conflitos em mídias sociais considerando diferentes formas de comportamento negativo observadas em interações online. Diferentemente de abordagens tradicionais binárias, os autores modelam um espectro de conflitos que inclui categorias como provocação, crítica, sarcasmo, *trolling*, assédio e ameaças. Para avaliação, foram comparados modelos de linguagem populares da literatura, incluindo BERT, DistilBERT, GPT-2 e Flan-T5. Os resultados experimentais indicaram que abordagens baseadas em Transformers e modelos de linguagem pré-treinados são capazes de classificar diferentes categorias de conflito em mídias sociais, alcançando desempenho competitivo nas tarefas avaliadas [5].

Em uma aplicação relacionada, Samghabadi et al. [8] propuseram uma abordagem para a identificação automática de agressividade e comportamento misógino em publicações de redes sociais. Os autores utilizaram uma estratégia de aprendizado multitarefa, na qual ambas as tarefas são aprendidas simultaneamente por meio de uma arquitetura compartilhada, composta por um modelo BERT pré-treinado, uma camada de atenção e um conjunto de camadas totalmente conectadas, seguidas por camadas de classificação específicas para cada tarefa. Diferentemente do procedimento tradicional de ajuste fino, os parâmetros do BERT foram mantidos congelados durante o treinamento, sendo utilizados apenas como fonte de representações contextuais dos textos. A camada de atenção foi utilizada para atribuir diferentes pesos aos *tokens* da sequência e gerar uma representação agregada da sentença, utilizada pelas tarefas de classificação de agressão e misoginia. Os resultados obtidos

mostraram que a combinação entre representações contextuais e aprendizado multitarefa permite identificar diferentes formas de comportamento agressivo em múltiplos idiomas, alcançando desempenho competitivo na competição TRAC-2 [8].

Em outro estudo relacionado, Saleh, Alhothali e Moria [7], investigaram a detecção automática de discurso de ódio em redes sociais por meio da comparação entre abordagens baseadas em aprendizado profundo. Primeiramente, os autores treinam um modelo *Word2Vec*, utilizado para gerar representações vetoriais (*embeddings*) das palavras a partir de seu contexto de ocorrência, sobre um *corpus* específico de discurso de ódio, produzindo representações mais adequadas ao vocabulário característico deste domínio, as quais são utilizadas como entrada de um modelo BiLSTM (Bidirectional Long Short-Term Memory), que consiste em uma rede neural recorrente bidirecional. Em seguida, comparam essa abordagem a *embeddings* de domínio geral, como Google Word2Vec e GloVe, além de um modelo baseado em BERT ajustado por *fine-tuning*. Os resultados mostram que, embora os *embeddings* especializados representem melhor o vocabulário característico do domínio, o BERT apresenta o melhor desempenho geral na detecção de discurso de ódio. Desta forma, os autores concluem que modelos pré-treinados, como o BERT oferecem maior capacidade de generalização, embora *embeddings* específicos de domínio permaneçam úteis para representar termos característicos de comunidades que produzem discurso de ódio.

Em suma, a literatura recente evidencia o protagonismo das arquiteturas baseadas em Transformers, especialmente o BERT, como estado da arte em tarefas de comportamentos hostis em ambientes digitais, incluindo discurso de ódio, agressividade e conflitos. Além disso, os estudos demonstram que o uso de representações contextuais de linguagem e o ajuste fino de modelos pré-treinados contribuem significativamente para o desempenho dessas aplicações. Nesse contexto, o presente trabalho adota uma abordagem baseada no BERTimbau, modelo pré-treinado para a língua portuguesa, com o objetivo de investigar sua aplicação na detecção automático de conflito em interações da plataforma X, considerando as particularidades linguísticas do português do Brasil e de um conjunto de dados especificamente construído para essa finalidade.

4 MATERIAIS E MÉTODOS

4.1 Construção do corpus

Esta subseção descreve as principais etapas envolvidas na construção do *corpus* utilizado neste trabalho, desde a origem dos dados até a obtenção do *corpus* anotado empregado no treinamento e na avaliação do modelo proposto. O produto final desse processo é um conjunto de dados formado por pares de tweets (tweet1, tweet2), cada par associado a um rótulo *conflito* ou *não conflito*.

4.1.1 Origem dos dados

Os dados utilizados neste projeto consistem em um conjunto de postagens públicas, em língua portuguesa, coletadas no âmbito do projeto de pesquisa *Observatório de Conflitos da Internet* [27] entre abril/2020 e julho/2020.

Nesse projeto, foi realizada uma coleta de publicações da plataforma X (antigo Twitter), direcionada a temas de relevância social e política em evidência no período analisado, resultando em diferentes conjuntos temáticos de publicações. Cada conjunto reúne postagens referentes a um mesmo tema de interesse, organizadas de acordo com o tópico abordado. A metodologia de coleta e a caracterização completa da pesquisa são descritas em [28].

Para o desenvolvimento deste trabalho, foram selecionados quatro desses conjuntos temáticos: Aborto [28], Cloroquina [28,29], Contas suspensas [28] e Mandetta [28]. A Tabela 1 apresenta as estatísticas descritivas desses conjuntos de dados.

Tabela 1 – Informações gerais dos conjuntos de dados selecionados

Dataset	Nome	Data	URL	Postagens totais
D03	Aborto	15/04/2020	bit.ly/2VYXJfA	91.251
D05	Mandetta	16/04/2020	bit.ly/3yTA5zd	304.433
D10	Cloroquina	20/05/2020	bit.ly/2VVtZjh	314.250
D16	Contas Suspensas	24/07/2020	bit.ly/3ski36K	412.537

Fonte: Elaboração própria (2026)

Esses conjuntos constituíram a base de dados bruta utilizada neste trabalho. A partir deles, foram realizadas as etapas de preparação dos dados, geração dos pares de tweets e anotação descritas nas Seções seguintes.

4.1.2 Preparação e organização dos dados

Cada subconjunto temático foi originalmente disponibilizado em um formato estruturado, no qual cada tweet é representado como uma entidade composta por atributos e metadados organizados em pares chave-valor, conforme API da plataforma X [12]. A partir dessa estrutura bruta, realizou-se, em cada subconjunto temático, uma etapa de seleção de atributos, preservando-se apenas os metadados metodologicamente relevantes para a análise e recuperação das publicações, tais como o identificador do tweet, o conteúdo textual, o tema associado, os identificadores de tweets referenciados e os metadados referentes ao tipo de interação da publicação.


Como parte do pré-processamento, foram aplicados procedimentos de filtragem e limpeza dos dados com o objetivo de garantir a consistência do *corpus*. Essas etapas incluíram a remoção de URLs, menções a usuários, *emojis* e textos duplicados. Além disso, foram excluídas publicações órfãs do tipo resposta e citação, isto é, aquelas cujos tweets de origem não puderam ser recuperados e também publicações que referenciavam elementos visuais, como imagens.

Após o processo de preparação dos dados, as publicações de cada subconjunto temático foram agrupadas em três categorias funcionais:

- **Tweets originais:** publicações autônomas que não configuram respostas nem citações;
- **Respostas (*replies*):** publicações direcionadas explicitamente a outro tweet;
- **Citações (*quotes*):** publicações que incorporam e comentam um tweet de origem

Essa estrutura permitiu organizar as publicações em função das diferentes formas de interação presentes na plataforma e forneceu a base necessária para a etapa de geração dos pares de tweets. O Esquema 8 apresenta a organização dos *datasets* temáticos iniciais segundo as categorias de interação identificadas.

Esquema 5 - Organização dos *datasets* iniciais



Fonte: Elaboração própria (2026)

Os conjuntos resultantes representam a estrutura inicial dos *datasets* temáticos utilizados neste trabalho, preservando tanto as características textuais das publicações quanto suas relações de interação na plataforma. A partir dessa estrutura, os tweets foram utilizados para a construção dos pares de interação textual que compõem as unidades de análise do *corpus* anotado. A estratégia adotada para a formação desses pares, considerando as diferentes categorias de interação identificadas, é apresentada na seção seguinte.

4.1.3 Geração de pares e amostragem aleatória

Para cada *dataset* temático construído na seção anterior, foram gerados pares de interação textual a partir das relações estruturais entre os tweets. Para os tweets classificados com (ii) respostas (*replies*), foram formados pares entre cada resposta e o seu respectivo tweet de origem, desde que ele esteja disponível no conjunto de dados. De forma análoga, para os tweets da categoria (iii) citações (*quotes*), foram gerados pares compostos pelo tweet que contém a citação e o respectivo tweet citado.

Para os tweets da categoria (i), isto é, tweets originais que não configuram respostas nem citações, foi adotada uma abordagem de amostragem aleatória. Nessa estratégia, pares de tweets são selecionados aleatoriamente dentro dessa classe, formando combinações no

formato (tweet1, tweet2). Essa amostragem representa um subconjunto do espaço de todas as possíveis combinações entre pares de tweets desta categoria.

A escolha desta abordagem é viabilizada pela natureza homogênea dos subconjuntos temáticos, nos quais os tweets compartilham um mesmo contexto ou tópico geral. Essa característica permite que a amostragem aleatória produza pares potencialmente relevantes para a análise de relações semânticas entre os tweets, mesmo na ausência de vínculos explícitos entre os elementos pareados. Além disso, como os tweets da categoria (i) não apresentam relações estruturais diretas, diferentemente das categorias (ii) e (iii), a amostragem aleatória evita a introdução de vieses estruturais, como a tendência de modelos privilegiarem padrões de interação, o que poderia limitar a diversidade de relações discursivas observadas.

Por fim, trata-se de uma abordagem simples e de baixo custo computacional, quando comparada a métodos baseados em similaridade semântica ou heurística mais complexa, mantendo-se adequada ao objetivo de gerar um conjunto representativo equilibrado de interações. Ao final do procedimento, obtêm-se novos *datasets* temáticos, compostos por pares de tweets daquele determinado subconjunto temático, acompanhados de sua respectiva classe de origem (i, ii, iii).

4.1.4 Critérios e mecânica de anotação

A classificação dos pares de tweets quanto à presença de conflito foi orientada pela definição adotada neste trabalho, apresentada na Seção 3.2. Antes do início da anotação, os avaliadores realizaram um processo de alinhamento com o objetivo de uniformizar a interpretação dessa definição e reduzir ambiguidades durante a classificação. Como apoio às decisões, foram considerados aspectos como a existência de interação interpretável entre os textos, o objeto da discussão, a oposição de posicionamentos e a presença de manifestações de antagonismo, sem que esses elementos constituíssem critérios rígidos de decisão.

Para os pares de tweets originais, obtidos por amostragem aleatória, adotou-se uma definição não ordenada de conflito. Nesses casos, o par (tweet_A, tweet_B) foi considerado *conflituoso* sempre que houvesse indícios de conflito em qualquer direção de interpretação entre os textos. A abordagem mantém-se consistente com o objetivo de capturar relações de conflito em nível semântico, não se restringindo necessariamente a uma estrutura discursiva direcionada.

A anotação foi realizada por dois avaliadores independentes (os autores deste trabalho), buscando-se manter uma distribuição equilibrada de pares entre os diferentes

subconjuntos temáticos. Os pares foram classificados nas categorias *conflito*, *não conflito* ou *indeterminado*, sendo esta última reservada aos casos em que não foi possível estabelecer, com segurança, a presença ou a ausência de conflito. As instâncias classificadas como *indeterminadas* foram mantidas no *corpus* final, porém excluídas das etapas de treinamento e avaliação do modelo.

A consolidação dos rótulos finais seguiu uma mecânica de votação por maioria. Nos casos de concordância entre os dois avaliadores, o rótulo foi incorporado diretamente ao corpus. Nas situações de divergência, o par foi submetido à avaliação de um terceiro avaliador (o orientador deste trabalho), sem acesso às classificações anteriores, para fins de desempate. Em caso de tripla divergência, o par foi classificado como *indeterminado*.

A consistência do processo de anotação foi avaliada por meio da comparação das classificações atribuídas pelos dois avaliadores, utilizando tabelas de contingência (matrizes de confusão) e métricas de concordância. Os resultados dessa análise são apresentados na Seção 5.1.2.

4.1.5 Estratégia de anotação em múltiplas etapas

Após a definição dos critérios operacionais, a construção do *corpus* anotado foi realizada de forma incremental ao longo de três etapas sucessivas. Essa estratégia, inspirada nos princípios de Aprendizado Ativo (*Active Learning*), foi adotada com o objetivo de mitigar o desbalanceamento natural dos dados, ampliar a representação da classe de interesse (*conflito*) e direcionar o esforço dos anotadores para regiões do espaço amostral com maior potencial informativo.

- **Etapas 1 - Seleção aleatória de amostras:** A primeira fase consistiu na amostragem puramente aleatória de pares de tweets para classificação manual pelos anotadores, seguindo o protocolo de homologação detalhado na Seção 4.1.4. O propósito desta etapa foi estabelecer uma linha de base que refletisse a distribuição real e o desbalanceamento natural do fenômeno na plataforma X.
- **Etapas 2 - Seleção de amostras induzida por modelo:** Com a finalidade de aumentar a representatividade da classe minoritária (*conflito*), um modelo BERT foi inicialmente treinado utilizando os dados anotados na etapa anterior. Em seguida, o modelo foi utilizado para estimar a probabilidade de conflito em pares ainda não anotados. As instâncias foram ordenadas de acordo com essa probabilidade e

submetidas à revisão pelos anotadores, priorizando exemplos considerados potencialmente conflitantes pelo classificador.

- **Etapa 3 - Seleção exploratória de amostras:** Nessa fase, buscou-se ampliar a diversidade do *corpus* por meio de uma estratégia baseada na incerteza do modelo. Os exemplos candidatos foram organizados em blocos fixos de 100 instâncias, obedecendo à seguinte composição: (i) 50 pares situados na região de incerteza do classificador (probabilidade entre 40% e 60%); (ii) 25 pares localizados na região de alta confiança de predição (80% a 90%); e (iii) 25 pares selecionados aleatoriamente. Os pares assim selecionados foram submetidos ao processo de anotação manual.

Ao final do processo, obteve-se um corpus anotado, cujos resultados e características são apresentados durante a Seção 5.1.

4.2 Processo de ajuste fino do classificador

Esta subseção apresenta a metodologia empregada no processo de ajuste fino do classificador utilizado neste trabalho, contemplando a definição do modelo base, a divisão e preparação dos dados, as estratégias de balanceamento das classes, a configuração do treinamento e o ambiente computacional adotado nos experimentos

4.2.1 Modelo base

Este trabalho utiliza como base o modelo de linguagem pré-treinado BERTimbau Base [27], uma versão da arquitetura BERT pré-treinada para o português do Brasil. Para possibilitar a aplicação do modelo em uma tarefa supervisionada de classificação, foi utilizada a classe `BertForSequenceClassification`, disponibilizada pela biblioteca Hugging Face Transformers. Essa implementação utiliza o BERTimbau como codificador (*encoder*) das sequências de entrada e adiciona uma camada linear de classificação sobre a representação do token especial [CLS], possibilitando sua aplicação a tarefas supervisionadas de classificação de sequências.

O problema foi modelado como uma tarefa de classificação binária, na qual cada par de tweets recebe um dos rótulos *conflito* ou *não conflito*. Para isso, a camada de saída foi configurada com duas unidades (`num_labels = 2`), produzindo saída do tipo *logit*

correspondentes a cada categoria, posteriormente convertidos em probabilidades durante o processo de inferência.

A adaptação do modelo ao domínio desta pesquisa foi realizada por meio do processo de *fine-tuning*, no qual todos os parâmetros do BERTimbau foram ajustados utilizando o corpus anotado desenvolvido neste trabalho. As etapas empregadas nesse processo são descritas nas seções seguintes.

4.2.2 Divisão dos dados

Para avaliar adequadamente a capacidade de generalização do modelo, o conjunto de dados foi dividido em três subconjuntos distintos: *treinamento*, *validação* e *teste*. O conjunto de treinamento foi utilizado para o ajuste dos parâmetros do modelo durante o processo de aprendizagem, enquanto o conjunto de validação foi empregado para acompanhar a performance ao longo das épocas de treinamento e selecionar a configuração de melhor desempenho. Por fim, o conjunto de teste foi reservado exclusivamente para a avaliação final do classificador, garantindo uma estimativa imparcial de sua capacidade de generalização.

Entretanto, devido à estratégia de construção do *corpus* utilizada neste trabalho, a divisão dos dados não foi realizada de maneira completamente aleatória. Conforme descrito na Seção 4.1.5, as Etapas 2 e 3 de anotação foram construídas por meio de um processo de anotação induzido. Caso esses dados fossem utilizados para avaliação final, haveria risco de superestimar o desempenho obtido. Desta forma, visando mitigar este problema, a divisão dos conjuntos foi realizada considerando a origem dos exemplos em cada etapa de anotação.

O conjunto de teste foi formado exclusivamente por exemplos provenientes de amostragem aleatória. Para isso, foram reservados 30% dos dados da Etapa 1 de anotação, enquanto os exemplos restantes dessa etapa foram incorporados a um conjunto intermediário de desenvolvimento.

O conjunto intermediário foi formado pela combinação dos 70% dos dados restantes da Etapa 1 com todos os exemplos obtidos por anotação induzida nas Etapas 2 e 3. Posteriormente, esse conjunto foi dividido em 80% para treinamento e 20% para validação. Tanto essa divisão quanto a separação inicial dos dados da Etapa 1 foram realizadas de forma estratificada em relação às classes, preservando a proporção original entre exemplos de *conflito* e *não conflito* em cada subconjunto. Dessa forma, o conjunto de teste mantém a distribuição real das classes presente na amostragem aleatória do corpus, e oferece uma avaliação mais representativa da capacidade de generalização do modelo.

4.2.3 Pré-processamento dos dados

Após a etapa de divisão do conjunto anotado, foi realizada a preparação dos dados para o treinamento do modelo BERTimbau. Esta fase teve como objetivo adequar as sequências textuais ao formato de entrada exigido pela arquitetura do modelo, por meio do processo de tokenização.

A *tokenização* foi realizada utilizando o *tokenizador* do BERTimbau, responsável por converter o texto em uma sequência de subpalavras (*subword tokenization*) e convertê-las em identificadores numéricos pertencentes ao vocabulário do modelo. Como a abordagem proposta considera pares de tweets, as entradas foram estruturadas no formato [CLS] texto_1 [SEP] texto_2 [SEP], permitindo que ambas as mensagens fossem processadas conjuntamente pelo modelo durante a etapa de classificação.

Além dos identificadores dos *tokens* (*input_ids*), o processo de *tokenização* gera automaticamente os vetores *token_type_ids*, utilizados para distinguir os *tokens* pertencentes a cada sentença do par, e *attention_mask*, responsável por indicar quais posições correspondem a tokens válidos e quais pertencem ao preenchimento (*padding*).

Foi adotado um comprimento máximo de 128 *tokens* para cada exemplo. Esse limite é suficiente para representar a grande maioria dos pares de tweets utilizados neste trabalho, uma vez que as publicações da plataforma X possuem extensão limitada por natureza. Sequências com tamanho superior a esse limite foram truncadas, sendo removidos *tokens* da sequência mais longa até que o comprimento máximo fosse atingido. Já as sequências com comprimento inferior ao limite estabelecido foram preenchidas (*padding*) até atingir o tamanho máximo especificado. Esse preenchimento é necessário para que todas as sequências de um mesmo lote (*batch*) possuam o mesmo comprimento, conforme requerido pelo formato de entrada utilizado pela arquitetura BERT, permitindo sua representação em tensores de dimensão fixa e o processamento paralelo durante o treinamento do modelo.

4.2.4 Treinamento do modelo

O treinamento foi realizado utilizando a *API Trainer*, disponibilizada pela biblioteca *Hugging Face Transformers*, responsável por gerenciar as etapas de treinamento, validação e avaliação do modelo.

Para a taxa de aprendizado, hiperparâmetro responsável por controlar a intensidade das atualizações realizadas nos pesos da rede durante o processo de otimização, foi adotado o

valor de 1×10^{-5} . A escolha desse valor foi baseada em experimentações preliminares realizadas durante o processo de ajuste fino, buscando um equilíbrio entre a adaptação do modelo ao corpus anotado e a estabilidade do processo de treinamento.

O *batch size* foi definido como 8, indicando que o modelo processa oito pares de tweets antes de realizar uma atualização dos seus pesos durante o processo de otimização. Essa configuração foi estabelecida considerando as limitações de memória da Unidade de Processamento Gráfico (GPU) utilizada nos experimentos, buscando um equilíbrio entre o uso dos recursos computacionais disponíveis e a estabilidade do processo de otimização.

O treinamento foi executado durante 4 épocas, correspondendo a quatro passagens completas pelo conjunto de treinamento. A quantidade de épocas foi definida com base em experimentações preliminares e no acompanhamento do desempenho do modelo durante a validação, buscando um equilíbrio entre a adaptação ao corpus anotado e a capacidade de generalização.

Também foi empregado *weight decay* (decaimento de pesos) igual a 0,01, técnica que restringe o crescimento excessivo dos pesos da rede. Seu objetivo é evitar que determinados parâmetros assumam valores excessivamente elevados durante o ajuste fino, mitigando a incidência de sobreajuste durante o treinamento.

Como função de perda, foi utilizada a *Cross-Entropy Loss*. Essa função calcula o erro de classificação do modelo a partir das probabilidades previstas para cada classe e dos respectivos rótulos corretos. Considerando o desbalanceamento existente entre as classes, ela foi configurada com pesos distintos para cada classe (*class weights*), calculados automaticamente a partir da distribuição dos exemplos no conjunto de treinamento. Assim, erros cometidos sobre a classe minoritária (*conflito*) passaram a contribuir mais para o valor da perda e, consequentemente, exercer maior influência na atualização dos parâmetros do modelo.

A otimização dos parâmetros foi realizada utilizando o algoritmo AdamW, adotado na implementação do BERT. Sem entrar no formalismo matemático, esse algoritmo é responsável por atualizar os pesos da rede ao longo do treinamento, buscando minimizar a função de perda calculada a cada lote de exemplos.

Ao final de cada época, o desempenho do modelo foi avaliado utilizando o conjunto de validação, sendo selecionada automaticamente a versão com maior *F1-score* da classe *conflito*. A escolha dessa métrica deve-se ao desbalanceamento existente entre as classes do problema, uma vez que ela considera simultaneamente a precisão e a revocação, fornecendo uma avaliação mais representativa do desempenho da classe minoritária. Por fim, foi fixada a

semente pseudoaleatória (*seed*) igual a 42, de modo que etapas dependentes de aleatoriedade produzam resultados consistentes entre diferentes execuções, aumentando a reprodutibilidade dos experimentos.

4.2.5 Ambiente computacional

Os experimentos foram desenvolvidos na linguagem *Python* utilizando o ambiente *Google Colab*, com aceleração por GPU *NVIDIA Tesla T4*, empregada para a execução das operações de treinamento e inferência do modelo.

O processo de ajuste fino foi conduzido utilizando o *framework PyTorch* como base para a execução do modelo de aprendizado profundo. Sobre essa estrutura, foi empregada a biblioteca *Hugging Face Transformers*, que disponibiliza implementações de arquiteturas baseadas em Transformers e recursos necessários ao ajuste fino de modelos pré-treinados, incluindo o BERTimbau utilizado neste trabalho.

Para manipulação dos conjuntos de dados foi utilizada a biblioteca *Hugging Face Datasets*, responsável pela conversão, organização e disponibilização dos dados em um formato compatível com a API de treinamento. O treinamento e avaliação do modelo foram conduzidos por meio da API *Trainer*, integrada à biblioteca Transformers, enquanto o módulo *Accelerate* foi utilizado para gerenciar a execução otimizada do treinamento na GPU.

Também foram empregados módulos da biblioteca *Scikit-learn* para divisão dos conjuntos de treinamento, validação e teste, bem como para o cálculo das métricas de desempenho utilizadas na avaliação do modelo. Complementarmente, as bibliotecas *Pandas*, *NumPy* e *Matplotlib* foram utilizadas, respectivamente, para manipulação dos dados, operações numéricas e geração dos gráficos apresentados nos resultados. Por fim, a biblioteca *gdown* foi utilizada para automatizar o acesso aos arquivos armazenados no *Google Drive* durante a execução dos experimentos.

4.2.6 Estratégias para mitigação do desbalanceamento de classes

Conforme apresentado na Seção 4.1.5, o desbalanceamento entre as classes foi inicialmente considerado durante a construção e expansão do corpus, por meio das estratégias de anotação induzida e exploratória (Etapas 2 e 3). Embora essas etapas tenham ampliado a representação da classe minoritária, o conjunto de dados final ainda manteve a distribuição

desbalanceada, com predominância de instâncias da classe *não conflito* (cujas proporções são detalhadas na Seção 5.1).

Para reduzir o impacto desse desbalanceamento durante a etapa de aprendizado supervisionado, foram avaliadas diferentes abordagens no processo de modelagem. A estratégia incorporada à versão final do classificador consiste no ajuste da função de perda por meio de pesos de classe (*class weights*), conforme apresentado na Seção 4.2.4. Essa técnica modifica a contribuição de cada classe no cálculo da *Cross-Entropy Loss*, sem alterar a distribuição original dos dados de treinamento, aumentando a influência dos exemplos pertencentes à classe *conflito* durante a otimização dos parâmetros do modelo.

Adicionalmente, com o objetivo de comparar o desempenho da função de perda ponderada com estratégias baseadas em modificação da distribuição amostral, foram conduzidos experimentos exploratórios independentes utilizando técnicas de reamostragem (*undersampling* e *oversampling*), bem como uma versão *baseline* sem qualquer tipo de tratamento de desbalanceamento. Os resultados comparativos desses quatro cenários experimentais são apresentados na Seção 5.2.4.

4.3 Estratégia de avaliação

O desempenho do modelo foi avaliado por meio das métricas *acurácia*, *precisão*, *revocação* e *F1-score*, calculadas sobre os conjuntos de validação e teste. Durante o processo de ajuste fino, o conjunto de validação foi utilizado para comparar as diferentes estratégias de treinamento e selecionar a configuração de melhor desempenho, enquanto o conjunto de teste permaneceu isolado e foi empregado exclusivamente na avaliação final do modelo.

Considerando o desbalanceamento entre as classes, a análise priorizou especialmente o *F1-score* da classe *conflito* e o *F1-score* macro, de modo a valorizar o desempenho na classe minoritária sem desconsiderar o desempenho geral do modelo em ambas as classes. Adicionalmente, foram analisadas as matrizes de confusão, permitindo identificar a distribuição de acertos e erros, bem como a ocorrência de falsos positivos e falsos negativos.

Além da avaliação do modelo, também foi analisada a consistência do processo de anotação manual. Para isso, foram comparadas as classificações atribuídas pelos dois anotadores, contabilizando-se os casos de concordância e divergência. A partir desses valores, foi calculada a taxa de concordância entre os anotadores, utilizada como indicador da consistência da anotação. Os resultados dessas análises são apresentados na Seção 5.

5 RESULTADOS E DISCUSSÕES

5.1 Resultados do processo de anotação

Nesta subseção são apresentados os resultados referentes à construção do *corpus* anotado utilizado neste trabalho. Inicialmente, são descritas as estatísticas da coleta e do pré-processamento dos dados. Na sequência, são analisados os resultados do processo de anotação, contemplando a consistência entre os anotadores, a evolução do *corpus* ao longo das etapas de anotação e a distribuição dos pares homologados por tema e por tipo de interação:

5.1.1 Estatísticas dos dados coletados e pré-processados

Conforme descrito na Seção 4.1.1, este trabalho utilizou quatro conjuntos temáticos extraídos de uma base de dados proveniente do projeto de pesquisa *Observatório de Conflitos da Internet* [28]. A Tabela 1 apresenta a quantidade de publicações originalmente disponíveis em cada um desses conjuntos temáticos, antes da aplicação das etapas de pré-processamento.

Após a aplicação do pré-processamento descrito na Seção 4.1.2, foram removidas as publicações que não atendiam aos critérios estabelecidos para a construção do *corpus*. A distribuição das publicações remanescentes é apresentada na Tabela 2.

Tabela 2 - Quantidade de publicações disponíveis após o pré-processamento dos dados

Tema	Reply	Quote	Original	Total
Aborto	4191	3045	8146	15382
Mandetta	19732	20879	25625	66236
Cloroquina	22514	28211	16360	67085
Contas Suspensas	20856	16236	14429	51521
Total	67293	68371	64560	200224

Fonte: Elaboração própria (2026)

Observa-se que, após o pré-processamento, permaneceram 200.224 publicações distribuídas entre tweets originais, respostas e citações. Essas publicações constituíram a base para a geração dos pares de tweets e para o processo de anotação descrito na Seção 4.1.4. A Tabela 3 apresenta a quantidade de pares formados e disponíveis para anotação.

Tabela 3 - Quantidade de pares formados para anotação com os dados pré-processados

Tema	Reply	Quote	Original	Total
Aborto	1729	3028	10000	14757
Mandetta	6479	20800	10000	37279
Cloroquina	7057	28050	10000	45107
Contas Suspensas	5704	16161	10000	31865
Total	20969	68039	40000	129008

Fonte: Elaboração própria (2026)

5.1.2 Estatísticas do processo de anotação

Como descrito na Seção 4, referente aos Materiais e Métodos empregados, após a coleta dos dados, pré-processamento dos mesmos e definição do critério para *conflito*, a anotação foi realizada em pares por meio de diferentes etapas (descritas em 4.1.5), com segmentações em diferentes temas de tweets (Aborto, Mandetta, Cloroquina e Contas suspensas), e diferentes categorias de pares de tweets (Originais, Replies e Quotes).

Tabela 4 - Quantidade de dados anotados por tema em cada Etapa

Tema	Etapa 1	Etapa 2	Etapa 3	Total
Aborto	450	400	150	1000
Mandetta	450	400	150	1000
Cloroquina	400	400	150	950
Contas Suspensas	300	400	150	850
Total	1600	1600	600	3800

Fonte: Elaboração própria (2026)

A Tabela 5 apresenta a distribuição das convergências e divergências identificadas durante o processo de anotação, considerando cada tema analisado e as diferentes etapas de construção do *corpus*.

Tabela 5 - Quantidade de Convergências e Divergências por tema em cada Etapa

Tema	Etapa 1		Etapa 2		Etapa 3		Total	
	Conv.	Div.	Conv.	Div.	Conv.	Div.	Conv.	Div.
Aborto	404	46	340	60	127	23	871	129
Mandetta	405	45	365	35	133	17	903	97
Cloroquina	349	51	355	45	131	19	835	115
Contas Suspensas	280	20	359	41	133	17	772	78
Total	1438	162	1419	181	524	76	3381	419

Legenda:

Conv. (Convergência)

Div. (Divergência)

Fonte: Elaboração própria (2026)

A partir desses resultados, é possível observar a maior proporção de convergência das classificações, com 3381 (cerca de 88,97%), em comparação com as divergências obtidas, com 419 (cerca de 11,03%). Isso demonstra que o conceito de conflito adotado levou a uma alta taxa de concordância entre os anotadores, com as divergências partindo das diferenças de interpretação do conteúdo dos textos abordados, a falta de entendimento de uma das partes sob o conteúdo textual, a identificação de novos atributos que passaram a ser adotados no processo de anotação a partir do momento em que foram identificados, como no caso da ordem de interpretação da “conversa” formada nos pares de tweets originais podendo ser invertida, ou por fim o próprio erro humano envolvido no processo de anotação manual. Ao fim desse processo, consideramos que a alta concordância entre anotadores mostrou que a definição de conflito adotada deu origem a um critério de anotação consistente e reproduzível, justificando a continuidade do trabalho.

Por fim, os 3381 dados em que houve concordância foram automaticamente classificados como pares homologados, ou seja, prontos para serem utilizados. Dos 419 pares de tweets em que houve divergência entre os dois anotadores iniciais, 191 foram classificados

por um terceiro anotador, conforme descrito em 4.1.4, sendo adicionados ao conjunto de pares homologados. Restaram 228 pares que não passaram pelo processo de desempate e foram definidos como *indeterminados* e não foram utilizados em etapas posteriores. Isso resultou em um total de 3572 pares homologados para serem utilizados pelo modelo classificador.

5.1.3 Evolução do *corpus* anotado ao longo das etapas

Conforme descrito na Seção 4.1.4, a construção do *corpus* anotado foi realizada em três etapas sucessivas, baseadas em diferentes estratégias de seleção de exemplos. A Tabela 6 apresenta uma visão geral dos resultados obtidos em cada etapa, incluindo o número de pares homologados, a distribuição dos rótulos atribuídos e a proporção de exemplos classificados como *conflito*.

Tabela 6 - Estatísticas dos pares homologados

Etapas	Pares homologados	Conflitos	Não conflitos	Indeterminados	% Conflitos
Etapas 1	1525	336	1164	25	22,03
Etapas 2	1523	748	735	40	49,11
Etapas 3	524	153	364	7	29,20
Total	3572	1237	2263	72	34,63

Fonte: Elaboração própria (2026)


Ao final das três etapas, foram homologados 3572 pares de tweets, sendo 1237 classificados como *conflito* e 2263 como *não conflito* (o restante, *indeterminados*, foram desconsiderados na análise). Observa-se que a distribuição dos rótulos variou significativamente entre as etapas, refletindo o impacto das diferentes estratégias de seleção utilizadas na composição do corpus.

A primeira etapa, baseada em amostragem aleatória, revelou uma predominância da classe *não conflito*, indicando um desbalanceamento inicial entre as categorias analisadas. Esse resultado sugere que, na ausência de qualquer viés de seleção, a distribuição natural do conjunto de dados tende a apresentar maior frequência de interações classificadas como *não conflito*, de acordo com os critérios de classificação estabelecidos neste trabalho.

Nas etapas seguintes, observa-se uma alteração progressiva na composição do *corpus*. A segunda etapa apresentou um aumento expressivo na proporção de exemplos de *conflito* em relação à distribuição inicial, reduzindo o desbalanceamento identificado anteriormente e demonstrando a efetividade da estratégia aplicada.

Na terceira etapa, observou-se uma distribuição intermediária se comparada às anteriores. Embora a proporção de *conflitos* tenha se reduzido em relação à segunda etapa, ela permaneceu superior à observada na amostragem inicial. Essa variação indica que a estratégia da etapa foi efetiva em seu objetivo de prover uma composição mais equilibrada. O Gráfico 2 ilustra este comportamento ao apresentar a distribuição das classes ao longo das etapas de construção do *corpus*.

Gráfico 2 - Distribuição dos rótulos ao longo das etapas



Fonte: Elaboração própria (2026)

Ao final do processo, o *corpus* apresentou predominância da classe *não conflito*, preservando a característica observada na amostragem inicial, porém com maior quantidade e variedade de exemplos de *conflito*. Dessa forma, o processo incremental resultou em um conjunto de dados menos limitado pela distribuição inicial, ampliando a disponibilidade de exemplos relevantes para a etapa de treinamento do modelo.

5.1.4 Distribuição temática do *corpus*

Com o intuito de investigar a contribuição dos diferentes temas para a composição do *corpus* anotado, a Tabela 7 apresenta a distribuição dos rótulos de *conflito* e *não conflito* ao longo das três etapas de anotação para cada grupo temático investigado.

Tabela 7 - Distribuição temática das anotações do *corpus*


Tema	Etapa 1		Etapa 2		Etapa 3	
	Conflito	Não Conflito	Conflito	Não Conflito	Conflito	Não Conflito
Aborto	116	315	181	166	54	69
Cloroquina	117	267	208	174	35	95
Contas Suspensas	41	239	221	170	26	106
Mandetta	62	343	138	225	38	94

Fonte: Elaboração própria (2026)

Em termos gerais, os quatro temas responderam à estratégia incremental de forma semelhante, apresentando aumento da representatividade da classe *conflito* em relação à amostra inicial. Entretanto, a intensidade desse efeito variou entre os conjuntos temáticos, indicando que a incidência de interações conflituosas não ocorreu de maneira homogênea.

Na amostra inicial (Etapa 1), os temas Aborto e Cloroquina já apresentavam uma participação relativamente maior de conflitos quanto comparados aos demais, enquanto Mandetta e Contas Suspensas concentravam predominantemente interações classificadas como *não conflito*. Como essa etapa foi construída por amostragem aleatória, esse comportamento sugere diferenças inerentes à dinâmica discursiva de cada tema. O Gráfico 3 ilustra a distribuição dos rótulos atribuídos aos *datasets* temáticos anotados na Etapa 1.


Gráfico 3 - Distribuição dos rótulos ao longo dos grupos temáticos da Etapa 1



Fonte: Elaboração própria (2026)

Após a aplicação da estratégia de seleção induzida por modelo (Etapa 2), observa-se um aumento consistente da representatividade da classe *conflito* em todos os temas, porém com magnitudes distintas. O efeito foi particularmente expressivo em Contas Suspensas, que passou de uma forte predominância de exemplos *não conflituosos* para uma distribuição próxima ao equilíbrio entre as classes. Em contraste, o tema Mandetta apresentou comportamento peculiar: embora a estratégia de seleção tenha aumentado a quantidade de exemplos de *conflito*, esse foi o único tema em que a classe *não conflito* permaneceu claramente predominante. Este resultado sugere que as características das interações associadas a esse tema na amostra coletada representaram um desafio maior para a estratégia de seleção adotada nesta etapa. O Gráfico 4 apresenta o comportamento observado nos subconjuntos temáticos após a anotação.


Gráfico 4 - Distribuição dos rótulos ao longo dos grupos temáticos da Etapa 2



Fonte: Elaboração própria (2026)

Na Etapa 3, observa-se um comportamento intermediário entre as duas etapas anteriores. Embora todos os temas tenham mantido uma representatividade da classe *conflito* superior à observada na amostra inicial, a classe *não conflito* voltou a predominar em todos os subconjuntos. Ainda assim, Aborto apresentou a maior proporção relativa de *conflitos*, enquanto Mandetta permaneceu como o tema com menor representatividade dessa classe. O Gráfico 5 ilustra essa distribuição.


Gráfico 5 - Distribuição dos rótulos ao longo dos grupos temáticos da Etapa 3



Fonte: Elaboração própria (2026)

Embora a análise por etapa permita compreender os efeitos das diferentes estratégias de anotação empregadas ao longo da construção do *corpus*, torna-se igualmente relevante observar a distribuição temática considerando o conjunto final de dados. Para isso, o Gráfico 6 apresenta a consolidação dos pares anotados ao fim das três etapas para cada tema investigado.

Gráfico 6 - Distribuição dos rótulos por tema no *corpus* final



Fonte: Elaboração própria (2026)

No *corpus* final, Aborto e Cloroquina concentraram a maior representatividade da classe *conflito*, enquanto Mandetta apresentou a menor incidência relativa dessa classe e Contas Suspensas um comportamento intermediário. Embora as estratégias de anotação tenham alterado significativamente a composição dos subconjuntos ao longo da construção do *corpus*, observa-se que a contribuição relativa de cada tema para a classe conflito permaneceu semelhante à observada na amostra inicial, com Aborto e Cloroquina concentrando proporcionalmente mais exemplos conflituosos e Mandetta mantendo a menor participação.

Em conjunto, os resultados indicam que as estratégias de anotação ampliaram a representatividade da classe conflito em todos os temas, mas não de forma uniforme. Apesar das alterações promovidas ao longo das etapas, a distribuição temática observada no *corpus* final permaneceu coerente com a tendência identificada na amostra inicial, evidenciando que o enriquecimento da base ocorreu sem alterar substancialmente a contribuição relativa de cada tema para a composição do *corpus*.

5.1.5 Distribuição por classe do *corpus*

Além da análise temática apresentada na seção anterior, torna-se imperativo investigar como a ocorrência de *conflitos* varia entre os diferentes tipos de interação considerados na construção do *corpus*. A Tabela 8 apresenta a distribuição dos rótulos de *conflito* e *não conflito* nas classes de tweets (*reply*, *quote* e *original*) ao longo das três etapas de anotação.

Tabela 8 - Distribuição de anotações do corpus por classe de Tweet

Tema	Reply		Quote		Original	
	Conflito	Não Conflito	Conflito	Não Conflito	Conflito	Não Conflito
Etapa 1	150	375	99	426	87	363
Etapa 2	418	214	196	281	134	240
Etapa 3	52	53	50	200	51	111
Total	620	642	345	907	272	714
Total Agregado	1262		1252		986	

Fonte: Elaboração própria (2026)

Na Etapa 1, que representa a distribuição natural da amostra, observa-se que os *replies* apresentaram a maior proporção de *conflitos* (28,6%), seguidos pelos *originais* (19,3%) e pelos *quotes* (18,9%), conforme ilustrado no Gráfico 7. Esse comportamento sugere que respostas diretas tendem a concentrar uma frequência maior de interações antagônicas. De fato, este comportamento correspondeu às expectativas, uma vez que os *replies* constituem a forma mais explícita de interação entre usuários e, portanto, o tipo de estrutura onde esperava-se maior difusão de conflitos.


Por outro lado, os *quotes* apresentaram a menor proporção de *conflitos* na amostragem aleatória. Apesar desse tipo de publicação também estabelecer uma relação explícita com outro tweet, ela pode cumprir diferentes funções discursivas, como compartilhamento de informações, complementação de conteúdo ou divulgação de uma publicação, não estando necessariamente associada a manifestações de oposição. Já os *originais*, por mais que não possuam uma relação estrutural entre os elementos do par, apresentaram uma proporção de conflitos ligeiramente superior à observada nas citações, sendo aproximadamente 70% do

valor de incidência observada nos *replies*. Esse resultado sugere que, nos temas analisados, a ocorrência de conflito não depende exclusivamente da existência de uma interação direta entre os usuários. Em outras palavras, mesmo publicações produzidas de forma independente podem expressar posicionamentos incompatíveis quando inseridas em um mesmo contexto de debate público. Ainda assim, a menor proporção de *conflitos* em relação aos *replies* indica que a ausência de uma relação conversacional reduz a probabilidade de formação de pares antagônicos, uma vez que muitos pares gerados por amostragem aleatória abordam aspectos distintos de um mesmo tema, sem estabelecer oposição direta.

O comportamento observado na Etapa 2 evidencia o impacto da estratégia de seleção direcionada sobre a composição do *corpus*. Em todas as classes ocorreu um aumento expressivo da proporção de conflitos em relação à Etapa 1, indicando que a estratégia adotada cumpriu seu objetivo de ampliar a representatividade dessa classe. Esse efeito foi mais evidente nos *replies*, cuja proporção de conflitos passou de 28,6% para 66,1%, enquanto *quotes* e *originais* atingiram 41,1% e 35,8%, respectivamente.


Na Etapa 3, observa-se uma redução na proporção de conflitos em todas as classes, comportamento esperado em função da estratégia baseada na exploração de regiões de incerteza do classificador. Apesar disso, podemos observar que mesmo quando a seleção deixa de priorizar exclusivamente exemplos de alta probabilidade de *conflito*, *replies* continuam concentrando a maior taxa de ocorrência de interações antagônicas (49,5%). Um aspecto particularmente interessante nesta etapa é que os pares formados por tweets originais passaram a apresentar proporção de *conflitos* consideravelmente superior aos *quotes* (31,5% contra 20%). Esse comportamento indica que, nesta etapa, os pares de tweets originais contribuíram proporcionalmente mais para a composição da classe *conflito* do que os *quotes*, reforçando a importância da comparação entre publicações independentes na identificação de posicionamentos antagônicos dentro de um mesmo contexto temático. Para ilustrar a dinâmica de difusão de conflito ao longo das classes, o Gráfico 7 apresenta o mapa de calor do percentual de pares classificados como *conflito*, detalhando esses resultados por classe de tweet e etapa de anotação.

Gráfico 7 - Percentual de conflitos por classe de tweet e etapa de anotação



Fonte: Elaboração própria (2026)

Ao unificar as três etapas de anotação, observa-se que a distribuição absoluta dos rótulos preserva esse mesmo padrão discutido, como pode ser observado no Gráfico 8. *Reply* constitui a única classe em que as quantidades de *conflitos* (620) e *não conflitos* (642) estão praticamente equilibradas, evidenciando que esta classe representa a principal estrutura para ocorrência de interações conflituosas no *corpus*. Em contraste, os *quotes* apresentaram predominância expressiva de pares classificados como *não conflito* (907 contra 345 *conflitos*), enquanto os originais também mantiveram maior quantidade de exemplos não conflituosos (714 contra 272 *conflitos*). O Gráfico 8 ilustra esta distribuição.

Gráfico 8 - Distribuição de *conflitos* por classe de tweet no Dataset final

Fonte: Elaboração própria (2026)

De forma geral, os resultados indicam que a ocorrência de conflito está associada ao tipo de interação analisada. Estruturas que envolvem resposta direta entre usuários apresentam uma maior tendência à manifestação de antagonismos, enquanto citações e pares de tweets originais concentram predominantemente relações classificadas como *não conflituosas*. Esse comportamento reforça a importância de preservar essa diversidade na composição do *corpus*, de modo a contemplar diferentes contextos de manifestação do fenômeno. Além disso, a preservação dessas diferenças no *corpus* final contribui para que os modelos de classificação sejam treinados sobre exemplos representativos das diversas formas de interação presentes na plataforma, reduzindo o risco de especialização excessiva em um único tipo de estrutura.

5.2 Resultados do modelo especializado

Esta subseção apresenta os resultados obtidos pelo modelo BERTimbau ajustado na tarefa de classificação de pares de tweets em *conflito* e *não conflito*. Inicialmente, analisa-se o comportamento do treinamento ao longo das épocas, seguido da avaliação quantitativa do modelo no conjunto de teste e, por fim, da análise dos principais erros de classificação.

5.2.1 Divisão dos dados de treino e teste

Conforme descrito na seção 4.2.2, os dados homologados foram divididos em diferentes grupos com propósitos de uso específicos. Com a exclusão dos dados *indeterminados* do processo, a primeira divisão foi entre os grupos de treinamento e teste, com as seguintes quantidades advindas de cada etapa:

Tabela 9 - Divisão dos dados por Etapa de anotação

Grupo	Etapa 1	Etapa 2	Etapa 3	Total
Treinamento	1050	1483	517	3050
Teste	450	0	0	450

Fonte: Elaboração própria (2026)

Após essa formação, 20% dos dados presentes no grupo de treinamento foram redistribuídos para o grupo de validação, resultando na seguinte distribuição:

Tabela 10 - Distribuição final dos dados

Grupo	Total de dados
Treinamento	2440
Validação	610
Teste	450

Fonte: Elaboração própria (2026)

5.2.2 Evolução do modelo durante o ajuste fino

O processo de ajuste fino do modelo BERTimbau Base foi acompanhado ao longo de quatro épocas de treinamento, monitorando-se tanto a função de perda (*loss*) quanto as principais métricas de classificação obtidas sobre o conjunto de validação. O objetivo dessa análise é verificar o comportamento da aprendizagem do modelo, identificar possíveis sinais de sobreajuste (*overfitting*) e avaliar a estabilidade das métricas durante o treinamento. A Tabela 11 apresenta um resumo dos resultados obtidos durante o treinamento do modelo.

Tabela 11 - Métricas obtidas em cada época de treinamento


Métrica	Época 1	Época 2	Época 3	Época 4
Training Loss	0,641	0,472	0,370	0,306
Validation Loss	0,517	0,474	0,484	0,480
Acurácia	0,761	0,770	0,785	0,790
Precisão (Weighted)	0,778	0,797	0,812	0,806
Recall (Weighted)	0,761	0,770	0,785	0,790
F1 (Weighted)	0,764	0,774	0,789	0,793

Fonte: Elaboração própria (2026)

Observa-se inicialmente que a *training loss*, que representa o erro do modelo sobre o conjunto de treinamento, apresentou redução contínua ao longo das quatro épocas. Esse comportamento indica que o modelo foi gradativamente aprendendo os padrões presentes nos dados de treinamento.

Em contrapartida, a *validation loss*, calculada sobre o conjunto de validação, apresentou comportamento distinto. Após uma queda inicial entre as primeiras épocas, a métrica passou a oscilar em um patamar muito próximo, alternando entre leves aumentos e reduções discretas. Esse padrão indica que, após o avanço inicial, os ganhos na capacidade de generalização do modelo tornaram-se marginais. O Gráfico 9 apresenta a evolução das curvas das funções de perda durante o treinamento.

Gráfico 9 - Evolução das funções de perda durante o treinamento




Fonte: Elaboração própria (2026)

Embora a divergência entre as curvas de treinamento e validação nas últimas épocas indique o início de um leve processo de sobreajuste (*overfitting*), o aumento da perda de validação foi pequeno, permanecendo próxima ao menor valor observado durante o treinamento. Além disso, as métricas de classificação continuaram apresentando evolução ao longo das épocas, indicando que o modelo preservou boa capacidade de generalização durante o processo de ajuste fino.

Além da função de perda, foram analisadas as principais métricas de classificação obtidas sobre o conjunto de validação. O Gráfico 10 apresenta a evolução da acurácia, da precisão, do *recall* e do F1-score ponderados (*weighted*) durante o treinamento.

Gráfico 10 - Evolução das principais métricas de avaliação durante o treinamento



Legenda: Medido no conjunto de validação

Fonte: Elaboração própria (2026)

Observa-se que todas as métricas de classificação apresentaram evolução consistente ao longo do treinamento, indicando que o modelo continuou refinando sua capacidade discriminativa mesmo após a estabilização da *validation loss*. A pequena oscilação observada na precisão ponderada na última época não comprometeu o desempenho global, que atingiu seus melhores resultados ao final do treinamento. Em conjunto, esses resultados indicam que o modelo continuou aprendendo padrões relevantes para a tarefa de classificação ao longo do ajuste fino, refletindo-se na melhoria das métricas globais de desempenho.

Como o objetivo principal deste trabalho consiste na identificação de pares de tweets classificados como *conflito*, torna-se relevante analisar especificamente o comportamento das métricas associadas a essa classe. A Tabela 12 apresenta a evolução da precisão, do *recall* e do F1-score da classe conflito ao longo das quatro épocas de treinamento.


Tabela 12 – Evolução das métricas da classe conflito durante o treinamento

Métrica	Época 1	Época 2	Época 3	Época 4
Precisão	0,646	0,647	0,662	0,680
<i>Recall</i>	0,788	0,841	0,863	0,824
F1-score	0,710	0,732	0,749	0,745

Fonte: Elaboração própria (2026)

Embora a Tabela 12 permite observar a evolução numérica dessas métricas, a análise visual das tendências ao longo do treinamento facilita a compreensão do comportamento do modelo. Nesse sentido, o Gráfico 11 apresenta a evolução da precisão, do *recall* e do F1-score da classe *conflito* durante as quatro épocas de treinamento.

Gráfico 11 - Evolução das métricas da classe *conflito* durante o treinamento



Legenda: Medido no conjunto de validação

Fonte: Elaboração própria (2026)

A evolução das métricas da classe *conflito* indica uma melhora progressiva da capacidade do modelo em identificar exemplos pertencentes a essa categoria ao longo do treinamento. Observa-se uma tendência de crescimento das métricas até a terceira época, momento em que o modelo atingiu seu melhor desempenho para a classe de interesse. Na quarta época, observa-se uma leve perda de desempenho, decorrente da redução do *recall*, que não foi compensada pelo aumento da precisão, resultando em uma pequena queda no F1-score.

Como o objetivo deste trabalho é maximizar a identificação de pares de tweets em *conflito*, o modelo da terceira época foi selecionado para as avaliações posteriores, por apresentar o melhor F1-score para a classe de interesse e, consequentemente, o melhor equilíbrio entre precisão e *recall*.

5.2.3 Avaliação do modelo treinado

Após a conclusão do treinamento, o modelo BERTimbau Base foi avaliado utilizando o conjunto de teste, composto exclusivamente por 450 exemplos não utilizados durante o processo de treinamento e validação, a fim de estimar a capacidade de generalização do classificador diante de dados inéditos. A Tabela 13 apresenta as métricas obtidas nessa configuração ao avaliar o conjunto de teste.

Tabela 13 – Desempenho do modelo no conjunto de teste

Classe	Precisão	Recall	F1-score	Nº de exemplos
Não conflito	0,912	0,865	0,888	349
Conflito	0,605	0,713	0,655	101
Média Macro	0,759	0,789	0,771	450
Média Ponderada	0,843	0,831	0,836	450
Acurácia do modelo			0,831	

Fonte: Elaboração própria (2026)

Em termos globais, o modelo apresentou desempenho satisfatório, alcançando acurácia de 0,831 e *F1-score* ponderado de 0,836, indicando boa capacidade de classificação considerando a distribuição das classes no conjunto de teste. Este valor, no entanto, deve ser interpretado com cautela, afinal o conjunto de dados apresenta desbalanceamento, o que pode superestimar o desempenho do classificador ao favorecer a classe majoritária.

Analisando as métricas restantes, observamos que o comportamento observado durante a validação manteve-se no conjunto de teste. A diferença entre o *F1-score* macro (0,771) e o *F1-score* ponderado (0,836) evidencia que o desempenho do modelo não é homogêneo entre as classes. Além disso, enquanto a classe *não conflito* continua sendo reconhecida com elevada consistência, a identificação de pares pertencentes à classe *conflito* permanece como a principal dificuldade do modelo.

A diferença entre precisão e *recall* da classe *conflito* também é coerente com a estratégia adotada durante o treinamento. A utilização de ponderação das classes favoreceu a identificação da classe minoritária, resultando em um *recall* superior à precisão. Considerando

os objetivos deste trabalho, esse comportamento é desejável, pois prioriza a identificação de pares potencialmente conflituosos.

Em relação à validação, observa-se uma redução moderada do desempenho no conjunto de teste, o que era esperado. O conjunto de validação foi constituído a partir do mesmo processo de construção do *corpus*, incluindo amostras provenientes das etapas de seleção induzida, que introduzem um viés favorável ao aprendizado das regiões mais informativas do espaço amostral. Já o conjunto de teste representa uma avaliação mais independente da capacidade de generalização do modelo, tornando natural a ocorrência de uma pequena perda de desempenho.

Apesar dessa redução, os resultados indicam que o modelo preserva boa capacidade de generalização e mantém o mesmo padrão de comportamento observado durante o desenvolvimento. Em particular, o desempenho alcançado na identificação da classe *conflito* demonstra que a abordagem é promissora para a tarefa proposta, embora ainda existam oportunidades de aprimoramento, sobretudo no equilíbrio do desempenho entre as classes.

5.2.4 Comparativo das estratégias de mitigação do desbalanceamento

Conforme descrito na Seção 4.2.6, foram avaliadas diferentes estratégias para lidar com o desbalanceamento entre as classes durante o treinamento do modelo. Para isso, foram realizados quatro experimentos independentes utilizando o mesmo modelo BERTimbau Base, variando apenas a estratégia de tratamento do desbalanceamento. A Tabela 14 apresenta os resultados obtidos no conjunto de teste.

Tabela 14 - Desempenho das estratégias de mitigação do desbalanceamento

Estratégia	Precisão (Conflito)	Recall (Conflito)	F1-Score (Conflito)	F1-Score Macro
Baseline (sem tratamento)	0,594	0,624	0,609	0,746
Undersampling	0,583	0,663	0,620	0,750
Oversampling	0,622	0,604	0,613	0,752
Weighted (pesos de classe)	0,605	0,713	0,655	0,771


Fonte: Elaboração própria (2026)

Observa-se que as quatro estratégias apresentaram desempenhos semelhantes, com pequenas variações entre as métricas avaliadas. Ainda assim, a abordagem baseada em pesos de classe (*weighted*) apresentou os melhores resultados entre as configurações avaliadas, justificando sua adoção como configuração final do modelo.

5.2.5 Análise quantitativa dos erros

Para compreender de forma mais detalhada o comportamento do modelo final, a matriz de confusão apresentada a seguir permite analisar a distribuição dos acertos e erros de classificação para cada classe.

Matriz de confusão 1 - Desempenho do modelo no conjunto de teste



Fonte: Elaboração própria (2026)

A matriz de confusão permite identificar os diferentes padrões de erro produzidos pelo modelo. Do ponto de vista da aplicação proposta neste trabalho, os falsos negativos da classe *conflito* merecem atenção especial, pois correspondem a situações em que pares de tweets efetivamente representam conflitos, mas que não foram corretamente reconhecidos pelo classificador. Dessa forma, sua investigação fornece evidências sobre as limitações do modelo em capturar os padrões linguísticos e discursivos característicos das interações conflituosas, permitindo avaliar se essas dificuldades estão associadas a determinados temas ou tipos de interação. Para tal, a Tabela 15 apresenta a distribuição dos exemplos de *conflito* e dos respectivos falsos negativos por tema, avaliados no conjunto de teste.

Tabela 15 – Distribuição dos *conflitos* e dos falsos negativos por tema

Tema	Quantidade de conflitos	Quantidade de Falsos negativos	Recall aproximado
Aborto	36	7	0,81
Cloroquina	34	10	0,71
Mandetta	18	9	0,50
Contas suspensas	13	3	0,77

Fonte: Elaboração própria (2026)

De maneira geral, o modelo apresentou desempenho semelhante entre os diferentes temas, com pequenas variações nas taxas de recuperação dos *conflitos*. A principal exceção foi o tema Mandetta, que apresentou *recall* consideravelmente inferior aos demais, indicando maior dificuldade do modelo em reconhecer conflitos nesse contexto. Embora esse tema possua menor número de exemplos, a diferença observada em relação aos demais sugere que o comportamento não decorre apenas do tamanho da amostra, mas também de características específicas das interações presentes nesse conjunto. Esses resultados indicam que, embora o modelo apresente comportamento relativamente consistente entre a maioria dos temas, determinadas características discursivas podem reduzir sua capacidade de generalização em contextos específicos.

Além disso, é possível verificar a certeza média de *não conflito*, para cada tema, que o preditor definiu para esses pares.

Tabela 16 – Certeza Média de Não Conflito dos falsos negativos por tema

Tema	Aborto	Mandetta	Cloroquina	Contas Suspensas
Certeza Média de Não Conflito	76%	90%	80%	92%

Fonte: Elaboração própria (2026)

Observa-se que são valores elevados, o que significa que ele está errando com convicção, não se encaixando na faixa de certeza intermediária, que representaria casos mais difíceis de se classificar.

A fim de avaliar a distribuição dos falsos negativos segundo a estrutura da interação, a Tabela 17 apresenta a quantidade de exemplos de *conflito* e dos respectivos falsos negativos para cada tipo de interação entre os tweets.

Tabela 17 – Distribuição dos conflitos e falsos negativos por tipo de interação

Classe	Quantidade de conflitos	Quantidade de Falsos negativos	Recall aproximado
Original	22	5	0,77
Reply	57	17	0,70
Quote	22	7	0,68

Fonte: Elaboração própria (2026)

Diferentemente da análise por tema, o desempenho apresentou menor variação entre os diferentes tipos de interação. Embora *replies* e *quotes* tenham exibido valores de *recall* ligeiramente inferiores ao observado para tweets originais, as diferenças foram modestas, sugerindo que a estrutura da interação exerceu influência limitada sobre a capacidade de detecção do modelo.

Em conjunto, esses resultados sugerem que a variação do desempenho esteve mais associada à temática das interações do que ao seu tipo estrutural. Dessa forma, as dificuldades do classificador parecem estar mais relacionadas às características discursivas presentes em determinados contextos temáticos do que ao formato da interação entre os tweets. Essa observação motivou uma investigação qualitativa dos falsos negativos, apresentada na Seção seguinte, com o objetivo de identificar quais características linguísticas e discursivas estão associadas a esses erros.

5.2.6 Caracterização dos falsos negativos

Com o objetivo de entender melhor os erros cometidos pelo modelo, os 29 falsos negativos foram estudados/inspecionados manualmente. Observou-se que parcela significativa desses casos apresentava características que dificultam a identificação automática de conflitos, nas quais foram quantificadas na tabela a seguir. Um mesmo par pode ter mais de uma característica que possa dificultar a sua classificação, por conta disso, o somatório dessa quantificação não totaliza no número de falsos negativos identificados.

Tabela 18 – Quantidade de ocorrências dos motivos para os falsos negativos

Motivo	Quantidade
Crítica indireta	10
Polidez estratégica	10
Ironia/sarcasmo	8
Estrutura argumentativa agressiva	6
Necessita de contexto	5
Multi-turno/dependência de thread	3
Marcações de tom	1
Ambiguidade	1

Fonte: Elaboração própria (2026)

Não foram registrados casos de falsos negativos por motivos de conflito por omissão/silenciamento, variação de registro/gírias, negação atenuada/duplo sentido ou conflito implícito por pressuposição.

Nota-se o destaque para conflitos com a presença de uma crítica indireta, em que o ataque não é necessariamente expresso diretamente para o autor do tweet pareado, mas para um grupo em que ele faz parte ou uma pessoa que ele apoia, com o uso de uma polidez estratégica, em que as críticas presentes invalidam o tweet anterior sem envolver nenhuma ofensa, fazendo com que ele não detecte o conflito, seguido por aqueles expressos por ironia ou sarcasmo, que são figuras de linguagem em que se diz o oposto do que realmente se pensa ou se quer comunicar, mas com um tom ácido, zombeteiro ou de desprezo. Vale a menção aos casos com o motivo de multi-turno/dependência de thread, no qual em sua maioria

representam casos em que ele não detectou a possibilidade da inversão de ordem adotada para a interpretação entre os pares de tweets originais.

Para demonstrar alguns desses casos de falsos negativos e os motivos identificados para tais, a seguir demonstramos alguns exemplos selecionados:

Tipo: Quote

Tweet 1: “Canais de fake news sobre Covid-19 no YouTube são vistos quase 3 vezes mais que os de dados reais - estudo do Cepedisa, LAUT e INCT.DD, do e , mostra alcance de redes de teoria da conspiração e tratamentos médicos não comprovados”

Tweet 2: “Fake news: dizer que cloroquina funciona. Esse senhora é uma piada em forma de gente.”

Motivo: Uso de crítica indireta (usa o termo “esse senhora”, pode confundir o classificador achando que não é direto ao par) e estratégia argumentativa agressiva (ataque a credibilidade do par).

Tipo: Quote

Tweet 1: “Grande dia As contas dos pilantras dos passapanistas e de corruptos caindo. BOB Jefferson- corrupto VEIO DA HAVAN BERNADO RABICÓ GENGIVÃO SARAH "guerrilheira" E pelo jeito vai ter mais. Tem q cair a do "MENTOR" dos pilantras a do "VEIO DA VIRGÍNIA"”

Tweet 2: “Os defensores da dEmOCrAcIa amam uma censura, quem diria”

Motivo: Ironia/sarcasmo (no segundo tweet) e marcações de tom com excesso do uso de CAPSLOCK de forma desregulada, pode confundir o classificador.

Por fim, um exemplo em que foi mais difícil de encaixar em um dos motivos e identificar o que pode ter causado o erro do classificador:

Tipo: Reply

Tweet 1: “A maioria esmagadora dos brasileiros é contrária à demissão de Mandetta: 76,2% dos entrevistados discordam do afastamento do ministro da Saúde, segundo pesquisa realizada pelo Atlas Político. Vc concorda com o resultado da pesquisa? via”

Tweet 2: “mentiroso eu sou a favor vaza mandetta, este ministro é um lixo.”

Motivo: Um ataque claro ao autor com um “mentiroso”, talvez tenha errado por conta de que muitos tweets pareados a esse tweet 1 foram classificados como *não conflito* por se tratar de uma pergunta, deixando assim aberto a todo tipo de resposta (desde que não ataque o autor da pergunta), ele ficou tendencioso a classificar qualquer coisa pareada nessa categoria. Nesse caso, foi classificado como motivo o uso de uma estrutura argumentativa agressiva.

Essa análise possibilita identificar as características em que o preditor mais teve dificuldade, e direcionam para trabalhos futuros o tipo de conteúdo que deve receber maior atenção na etapa de treinamento.

6 DISCUSSÃO

A avaliação realizada sobre o conjunto de teste demonstra que o modelo foi capaz de aprender padrões relevantes para a tarefa de identificação de conflitos em pares de tweets. Embora tenha apresentado desempenho elevado na identificação da classe *não conflito*, a classificação da classe *conflito* permaneceu significativamente mais desafiadora, refletindo-se principalmente na redução do *recall* e do *F1-score* dessa classe.

Uma das explicações para esse comportamento reside nas características do conjunto de dados. Embora estratégias de balanceamento tenham sido aplicadas nas etapas de anotação e durante o processo de treinamento, o *corpus* é naturalmente concentrado na classe *não conflito*, limitando a aprendizagem de padrões associados à classe minoritária. Além disso, a abordagem incremental de anotação, que priorizou exemplos mais informativos para ampliar a classe de interesse, alterou a distribuição natural dos dados da plataforma. Se por um lado isso aumentou a representatividade da classe, por outro introduziu vieses de amostragem que podem afetar as fronteiras de decisão do classificador. Nesse contexto, a utilização de um conjunto de teste composto predominantemente por exemplos provenientes da etapa de anotação aleatória buscou reduzir esse efeito na avaliação do modelo, tornando-a mais representativa de sua capacidade de generalização. A comparação entre os modelos obtidos após a primeira e a terceira etapas indica que o enriquecimento progressivo do *corpus* proporcionou ganhos de desempenho, sugerindo que os benefícios da estratégia adotada superaram os possíveis efeitos decorrentes do viés de amostragem.

Outro fator relevante que torna imperativo trazer à luz da discussão é a própria natureza desafiadora da tarefa em si. Diferentemente de problemas de classificação baseados na identificação de palavras ofensivas ou expressões explicitamente agressivas, a identificação de conflitos depende frequentemente da interpretação do contexto discursivo estabelecido entre os dois tweets. Em diversas situações, manifestações de conflito são expressas de maneira indireta, por meio de ironias, sarcasmos, críticas implícitas ou referências a acontecimentos externos, exigindo conhecimento contextual que nem sempre está presente apenas no par de mensagens analisado, o que foi reforçado pela Seção 5.2.6.

Diante desse cenário, algumas limitações da metodologia também podem ter contribuído para o desempenho observado. Conforme discutido em [9], a incorporação de um contexto conversacional mais amplo tende a favorecer tarefas de classificação em redes sociais. Assim, embora a utilização de pares de tweets represente um avanço em relação à

análise de mensagens isoladas, o contexto fornecido por apenas duas publicações pode ser insuficiente para o modelo caracterizar padrões em determinadas interações conflituosas. Desta forma, informações potencialmente relevantes, como o histórico da conversa, acontecimentos contemporâneos e conhecimento de mundo, não são consideradas durante a classificação e, em redes sociais, esses elementos frequentemente desempenham papel importante na interpretação das interações, especialmente em casos onde o conflito é construído de maneira implícita.

Ademais, identifica-se como limitação a diferença entre o domínio linguístico presente no *corpus* utilizado no pré-treinamento do BERTimbau e aquele observado nos dados empregados no ajuste fino. O modelo foi originalmente treinado a partir de textos em português do Brasil predominantemente formais e estruturados, enquanto a tarefa proposta envolve publicações da plataforma X, caracterizadas por uma linguagem mais informal, uso frequente de abreviações, simplificações textuais e ocorrência de ruídos decorrentes de erros de escrita. Essa diferença de domínio pode dificultar a adaptação das representações linguísticas aprendidas durante o pré-treinamento para capturar de forma mais precisa os padrões específicos da comunicação em redes sociais. Nesse sentido, trabalhos futuros podem explorar a ampliação do *corpus* anotado utilizado no ajuste fino ou a construção de modelos pré-treinados especificamente em textos oriundos de redes sociais, visando melhorar a capacidade de identificação de conflitos nesse tipo de conteúdo.

Apesar dessas limitações, os resultados obtidos demonstram que o modelo apresentou capacidade satisfatória para identificar conflitos em pares de tweets, alcançando *F1-score* de 0,65 para a classe de interesse mesmo diante de um problema caracterizado por desbalanceamento, linguagem informal e elevada variabilidade linguística. Esses resultados indicam que arquiteturas baseadas em modelos de linguagem contextualizados constituem uma alternativa promissora para tarefas de detecção automática de conflitos em mídias sociais.

7 CONCLUSÃO

Este trabalho apresentou uma abordagem para detecção automática de conflitos em pares de publicações da plataforma X, por meio da construção de um *corpus* anotado na língua portuguesa e do ajuste fino de um modelo baseado na arquitetura BERTimbau. Para isso, foi estabelecido um processo de anotação, organizado em múltiplas etapas, fundamentado em uma definição de conflito formulada a partir das discussões e conceitos identificados na literatura especializada.

Os resultados obtidos demonstraram que o processo de anotação apresentou elevada concordância entre os anotadores (88%), indicando que os critérios adotados produziram um processo de anotação consistente e reproduzível para a caracterização do fenômeno no conjunto investigado. Além disso, a estratégia de anotação em múltiplas etapas mostrou-se eficaz para ampliar a representatividade da classe minoritária durante a construção do corpus. Embora essa estratégia introduza um viés de amostragem, a comparação entre os resultados obtidos ao longo do desenvolvimento do modelo indica que os ganhos decorrentes do enriquecimento do conjunto de treinamento superaram os possíveis impactos desse viés.

Na etapa de classificação automática, os resultados indicam que o modelo foi capaz de identificar padrões relevantes para a tarefa, embora a classificação de exemplos da classe *conflito* permaneça significativamente mais desafiadora do que a da classe *não conflito*. As análises realizadas sugerem que essa dificuldade está relacionada principalmente ao caráter implícito de muitas manifestações de conflito, à limitação do contexto disponível para classificação e ao desbalanceamento natural entre as classes.

De forma geral, considera-se que os objetivos propostos foram alcançados. Apesar das limitações, a abordagem se mostrou promissora para a detecção automática de conflitos em redes sociais. Embora seu desempenho ainda não seja suficiente para substituir a análise humana, a solução desenvolvida apresenta potencial para atuar como ferramenta de apoio à triagem de grandes volumes de publicações, auxiliando pesquisadores e analistas na identificação de interações potencialmente conflituosas e reduzindo o esforço necessário para a inspeção manual dos dados.

Como perspectivas para trabalhos futuros, destacam-se a ampliação do conjunto de dados anotado, contemplando não apenas os temas investigados neste trabalho, mas também novos assuntos e maior diversidade de interações; a incorporação de informações contextuais mais amplas, como sequências completas de conversações, histórico das interações e

metadados da plataforma; e a investigação de estratégias de aprendizado ativo para otimizar o processo de anotação, priorizando exemplos mais informativos para o treinamento. Essas direções possuem potencial para ampliar a capacidade de generalização dos modelos e aprimorar a identificação de conflitos implícitos em ambientes de comunicação online.

REFERÊNCIAS

- [1] H. K. Azzaakiyyah, "The Impact of Social Media Use on Social Interaction in Contemporary Society," *Technology and Society Perspectives (TACIT)*, vol. 1, no. 1, pp. 1–9, 2023, doi: 10.61100/tacit.v1i1.33.
- [2] A. L. T. Cabral and M. F. Guaranha, "Interações digitais: conflito, argumentação e violência verbal nas redes sociais," *Linha D'Água*, vol. 34, no. 2, pp. 117–134, 2021, doi: 10.11606/issn.2236-4242.v34i2p117-134.
- [3] B. M. Souza and M. A. Vieira, "Uso das redes sociais, valores democráticos e confiança institucional no Brasil," *Em Tese*, vol. 19, no. 2, pp. 17–46, 2022.
- [4] D. Olegário, J. S. de Lima, and A. Coelho, "Os reflexos das redes sociais na participação cidadã e na formação da opinião pública: uma análise entre mobilização política e desinformação," *Revista FT*, 2025, doi: 10.69849/revistaft/fa10202506062150.
- [5] O. Warke, J. M. Jose, J. Breitsohl, and J. Wang, "Capturing the Spectrum of Social Media Conflict: A Novel Multi-objective Classification Model," in *Proc. ACM SIGIR Int. Conf. Theory Inf. Retrieval (ICTIR)*, 2024, pp. 215–225.
- [6] S. Kemp, "The Global State of Digital in April 2023," *We Are Social*, Apr. 27, 2023. [Online]. Available: <https://wearesocial.com/uk/blog/2023/04/the-global-state-of-digital-in-april-2023>. [Accessed: Nov. 1, 2025].
- [7] H. Saleh, A. Alhothali, and K. Moria, "Detection of Hate Speech Using BERT and Hate Speech Word Embedding With Deep Model," *Applied Artificial Intelligence*, vol. 37, no. 1, Art. no. 2166719, 2023.
- [8] N. S. Samghabadi, P. Patwa, S. Pykl, P. Mukherjee, A. Das, and T. Solorio, "Aggression and Misogyny Detection Using BERT: A Multi-task Approach," in *Proc. Second Workshop on Trolling, Aggression and Cyberbullying*, May 2020, pp. 126–131.
- [9] C.-W. Tsai, Y.-H. Huang, T.-K. Liao, D. F. S. Estrada, R. Latifah, and Y.-S. Chen, "Leveraging Conflicts in Social Media Posts: Unintended Offense Dataset," in *Proc. Conf. on Empirical Methods in Natural Language Processing (EMNLP)*, Miami, FL, USA, 2024, pp. 4512–4522.
- [10] R. Recuero, *Redes Sociais na Internet*. Porto Alegre, Brazil: Sulina, 2009.
- [11] J. Y. M. Nip and B. Berthelie, "Social Media Sentiment Analysis," *Encyclopedia*, vol. 4, no. 4, pp. 1590–1598, 2024, doi: 10.3390/encyclopedia4040104.
- [12] X Corp., "Data Dictionary," *X API Documentation*. [Online]. Available: <https://docs.x.com/x-api/fundamentals/data-dictionary>. [Accessed: Apr. 21, 2026].
- [13] B. S. Santana and L. A. Freitas, "Processamento de Linguagem Natural: Conceitos, Técnicas e Aplicações em Português," 3^a ed., 2024. [Online]. Available: <https://brasileiraspln.com/livro-pln/3a-edicao/parte-dominios/cap-redes-sociais/cap-redes-sociais.pdf>.
- [14] N. Lyamouri-Bajja, N. Genneby, R. Markosyan, and Y. Ohana, "Understanding Conflict," in *T-Kit No. 12: Youth Transforming Conflict*. Strasbourg, France: Council of Europe Publishing, 2012, pp. 45–96.

- [15] J. Allen, *Natural Language Understanding*, 2nd ed. Redwood City, CA, USA: Benjamin/Cummings Publishing, 1995. [Online]. Available: <https://pt.scribd.com/document/720897215/Natural-Language-Understanding>.
- [16] M. Bansal, "Big Data: Creating the Power to Move Heaven and Earth," *MIT Technology Review*, Sep. 2, 2014. [Online]. Available: <https://www.technologyreview.com/2014/09/02/250240/big-data-creating-the-power-to-move-heaven-and-earth/>.
- [17] K. Albrecht, "The Importance of Computational Social Science," Northwestern University, 2018. [Online]. Available: <https://amaral.northwestern.edu/blog/importance-computational-social-science>.
- [18] M. G. V. Nunes, *O Processamento de Línguas Naturais: Para Quê e Para Quem? Série ND-73*. São Carlos, Brazil: Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, 2008. [Online]. Available: http://wiki.icmc.usp.br/images/5/55/ND_73.pdf.
- [19] R. Ahmad, Y. Shaikh, and S. Tanwani, "Aspect Based Sentiment Analysis and Opinion Mining on Twitter Data Set Using Linguistic Rules," *Indian Journal of Science and Technology*, 2023. [Online]. Available: https://www.researchgate.net/publication/369427699_Aspect_Based_Sentiment_Analysis_and_Opinion_Mining_on_Twitter_Data_Set_Using_Linguistic_Rules.
- [20] M. I. Jordan and T. M. Mitchell, "Machine Learning: Trends, Perspectives, and Prospects," *Science*, vol. 349, no. 6245, pp. 255–260, 2015, doi: 10.1126/science.aaa8415.
- [21] Y. LeCun, Y. Bengio, and G. Hinton, "Deep Learning," *Nature*, vol. 521, no. 7553, pp. 436–444, 2015, doi: 10.1038/nature14539.
- [22] B. Min, H. Ross, E. Sulem, A. P. Ben Veyseh, T. H. Nguyen, O. Sainz, et al., "Recent Advances in Natural Language Processing via Large Pre-trained Language Models: A Survey," *ACM Computing Surveys*, vol. 56, no. 2, Art. no. 30, pp. 1–40, 2024, doi: 10.1145/3605943.
- [23] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, et al., "Attention Is All You Need," in *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, I. Guyon, U. von Luxburg, S. Bengio, H. Wallach, R. Fergus, and S. V. N. Vishwanathan, Eds. Red Hook, NY, USA: Curran Associates, 2017, pp. 5998–6008.
- [24] A. Rogers, O. Kovaleva, and A. Rumshisky, "A Primer in BERTology: What We Know About How BERT Works," *Transactions of the Association for Computational Linguistics*, vol. 8, pp. 842–866, 2020, doi: 10.1162/tacl_a_00349.
- [25] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," in *Proc. 2019 Conf. North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*, vol. 1, Minneapolis, MN, USA, 2019, pp. 4171–4186.
- [26] F. Souza, R. Nogueira, and R. Lotufo, "BERTimbau: Pretrained BERT Models for Brazilian Portuguese," in *Proc. Brazilian Conference on Intelligent Systems (BRACIS)*, Rio Grande, Brazil, 2020, pp. 403–417, doi: 10.1109/BRACIS51462.2020.00087.
- [27] Universidade Federal do ABC, "Observatório de Conflitos da Internet." [Online]. Available: <https://observa.pesquisa.ufabc.edu.br/>. [Accessed: Aug. 1, 2026].

- [28] C. A. Kamienski, C. L. C. Penteado, D. Goya, R. V. Rocha, L. M. Souza, D. V. B. Genova, D. Ramos, F. A. de França, F. E. Horita, and C. da Silva Santos, "Measuring Network Polarization and Political Sectarianism During the 2020 Pandemic," *IEEE Transactions on Computational Social Systems*, vol. 10, no. 4, pp. 1356–1371, 2023, doi: 10.1109/TCSS.2022.3159449.
- [29] F. O. de França, C. da Silva Santos, C. L. C. Penteado, D. H. Goya, L. M. de Souza, D. V. B. di Genova, D. F. S. Ramos, and C. A. Kamienski, "Dynamics of Conflicts on the Twitter Social Network: A Case Study on the Use of Chloroquine in Brazil," in *Proc. 54th Hawaii International Conference on System Sciences (HICSS)*, 2021, pp. 2628–2637.